Clasificación Multietiqueta de Anomalías de Rodilla en Resonancia Magnética con Supervisión Débil

Guillermo Cajo gcajos@uni.pe
Andre Carasas andre.carasas.o@uni.pe
Daniel Franco daniel.franco.s@uni.pe
Ivonne Lazo ivonne.lazo.g@uni.pe
David Grabiel david.grabiel.g@uni.pe
Joel Renojo joel.renojo.c@uni.pe

FIIS, Universidad Nacional de Ingeniería (UNI), Lima, Perú

Resumen

La resonancia magnética (RM) de rodilla es el estudio de referencia para evaluar ligamentos, meniscos y cartílago, pero leerla toma tiempo y depende del radiólogo. En este trabajo construimos un clasificador multietiqueta que predice doce hallazgos a partir de la serie sagital con supresión grasa, usando el conjunto RSNA Knee Abnormality Detection. La dificultad principal es que solo 58 estudios tienen etiqueta dorada (anotada por radiólogos); para el resto armamos etiquetas débiles a partir del reporte en texto libre, escrito en varios idiomas (nuestro extractor cubre nueve), con un extractor por reglas que validamos contra el conjunto dorado (acuerdo de 80.9 %, kappa macro de 0.553). Comparamos una CNN 2.5D diseñada desde cero contra una ResNet-50 preentrenada en ImageNet, ambas con un pooling por atención entre cortes. Sobre 53 estudios dorados disponibles, la ResNet-50 alcanza un AUC-ROC macro de 0.736 (IC 95 %: 0.676 a 0.785) frente a 0.645 de la CNN desde cero, una diferencia que se mantiene en el remuestreo bootstrap. Las ablaciones (pérdida focal, manejo de etiquetas ruidosas, ponderación por desbalance y uso del plano coronal en lugar del sagital) cambian el resultado por hallazgo, pero no el macro de forma significativa. El análisis con Grad-CAM muestra que el modelo preentrenado mira sobre todo la zona central de la articulación, lo que es plausible para el LCA pero no para el derrame ni el quiste de Baker.

1. Motivación

La RM de rodilla permite ver en un solo estudio lesiones de ligamentos, roturas de menisco, desgaste del cartílago, líquido en la articulación y lesiones del hueso. El problema es práctico: cada estudio trae varias series con decenas de cortes, el radiólogo tiene que revisarlas todas, y dos especialistas no siempre coinciden en lo que ven. Un sistema que marque de forma automática los hallazgos más probables podría ayudar a ordenar la lista de trabajo y a no pasar por alto lesiones.

Desde el punto de vista del aprendizaje profundo, el caso es interesante por tres razones. Primero, es multietiqueta: un mismo estudio puede tener al mismo tiempo derrame, rotura de menisco y artrosis, y cada hallazgo tiene una frecuencia muy distinta (la fractura aparece en pocos casos, el derrame en más de la mitad). Segundo, la etiqueta está a nivel de estudio, pero el hallazgo vive en unos pocos cortes, así que el modelo tiene que aprender dónde mirar sin que nadie se lo diga. Tercero, y lo más importante para este trabajo, casi no hay etiquetas verificadas: de 4,407 estudios, solo 58 tienen la anotación de un radiólogo. Lo que sí tiene cada estudio es su reporte clínico en texto libre, en uno de varios idiomas. Por eso una parte central del proyecto fue construir y validar nuestro propio extractor de etiquetas a partir de esos reportes, sabiendo que las etiquetas que salen de ahí tienen ruido.

2. Trabajos Relacionados

El trabajo más cercano es MRNet (Bien et al., 2018), que clasificó RM de rodilla en tres categorías (anomalía general, rotura de LCA y rotura de menisco) con una AlexNet preentrenada aplicada corte por corte y un pooling máximo entre cortes. Nuestro enfoque sigue esa misma idea de procesar cada corte con una red 2D y combinar después, pero amplía el problema a doce hallazgos y reemplaza el

pooling máximo por uno aprendido.

Para combinar los cortes usamos el pooling por atención propuesto por Ilse et al. (2018) dentro del aprendizaje de múltiples instancias (MIL). En MIL la etiqueta corresponde a una "bolsa" de instancias (aquí, los cortes de un estudio) y la red aprende qué instancias pesan más. Esto encaja con nuestra situación: sabemos que el estudio tiene una rotura de menisco, pero no en qué corte está.

Como columna vertebral preentrenada usamos ResNet-50 (He et al., 2016), cuyas conexiones residuales permiten entrenar redes profundas sin que el gradiente se pierda, con pesos aprendidos en ImageNet (Deng et al., 2009). Para el desbalance entre clases evaluamos la pérdida focal de Lin et al. (2017), que reduce el peso de los ejemplos fáciles y concentra el aprendizaje en los difíciles.

Sacar etiquetas de reportes de texto para entrenar modelos de imagen ya se ha hecho a gran escala. CheXpert (Irvin et al., 2019) armó un etiquetador por reglas para reportes de radiografía de tórax que distingue hallazgos positivos, negativos e inciertos, y se apoya en ideas de NegEx (Chapman et al., 2001) para detectar negaciones como "sin derrame". Snorkel (Ratner et al., 2017) formalizó la idea de combinar varias fuentes de etiquetas débiles con distinta calidad. Nuestro extractor sigue ese camino, pero tiene que lidiar con nueve idiomas. Para definir artrosis por compartimento nos guiamos por la definición por RM de Hunter et al. (2011). Finalmente, para interpretar las predicciones usamos Grad-CAM (Selvaraju et al., 2017), que combina los gradientes de una clase con los mapas de la última capa convolucional para resaltar las regiones que más influyen en la decisión.

3. Metodología

3.1. Datos

Usamos el conjunto de la competencia RSNA Knee Abnormality Detection (RSNA, 2026). Los archivos siguen la jerarquía `estudio / serie / corte.dcm`. El archivo `train_series.csv` describe las 24,371 series (entre 3 y 14 por estudio) con su plano (sagital, coronal o axial) y si la secuencia es sensible a líquido con supresión grasa. Los nombres de los archivos DICOM son identificadores aleatorios, así que el orden real de los cortes lo sacamos de la cabecera: proyectamos `ImagePositionPatient` sobre la normal del plano, calculada con `ImageOrientationPatient`. En una serie de prueba de 36 cortes esto dio un espaciado constante de 2.87 mm, lo que confirma que el orden es correcto.

Llamamos **etiqueta dorada** a las 58 filas del archivo de entrenamiento que traen las doce columnas llenas; son las anotaciones hechas por radiólogos. Los otros 4,349 estudios solo tienen el reporte. Las doradas se usan únicamente como conjunto de prueba final: no se entrena con ellas, no se eligen umbrales con ellas y no se usan para detener el entrenamiento. En nuestra copia local del conjunto faltaban 5 de esos 58 estudios (la descarga quedó incompleta), por lo que la evaluación con imágenes se hizo sobre **53 estudios dorados**. Los doce hallazgos siguen teniendo casos positivos en ese subconjunto (el que más pierde es el quiste de Baker, que baja de 12 a 9 positivos). En este informe usamos 58 solo cuando el análisis es de texto (validación de las etiquetas débiles contra el radiólogo), y 53 en todo lo que usa imágenes (prevalencia de prueba, métricas, intervalos y Grad-CAM). En el código este conjunto aparece como la partición `oro`.

3.2. Reducción de escala

Siguiendo la recomendación del enunciado, trabajamos con una sola secuencia y un subconjunto estratificado (Tabla 1). La muestra de entrenamiento se armó empezando por los hallazgos más raros, asegurando al menos 40 positivos por hallazgo cuando existían, y completando al azar hasta 500 estudios. De esos, 75 se separaron como *validación débil* para detener el entrenamiento y elegir umbrales.

3.3. Pipeline de etiquetas débiles

El extractor por reglas (código propio) procesa cada reporte en cinco pasos:

Tabla 1: Decisiones de reducción de escala.

Aspecto	Decisión
Secuencia y plano	Sagital sensible a líquido con supresión grasa (disponible en 4,150 de 4,407 estudios). Coronal solo en la ablación de plano.
Muestra	425 de entrenamiento + 75 de validación débil + 53 dorados.
Volumen por estudio	24 cortes de 256×256, remuestreo lineal en el eje de cortes.
Intensidad	Recorte por percentiles 1 y 99.5 de cada volumen y escala a 0 a 255.
Entrada al modelo	11 tripletes de cortes contiguos (2.5D), recorte de 224×224.
Peso en disco	Alrededor de 1.1 MB por estudio (archivo `.npz` comprimido).



Figura 1: Cinco de los 24 cortes de un volumen sagital ya preprocesado (estudio dorado). El orden sigue la posición anatómica real, no el nombre del archivo.

a) Normaliza el texto (minúsculas, sin tildes) y une las líneas cortadas.

b) Elimina la indicación clínica y los antecedentes, porque ahí aparecen dudas del médico que pidió el estudio y no hallazgos.

c) Parte el texto en cláusulas y detecta negaciones antes y después del término, en nueve idiomas ("sin rotura", "no fracture", "keine Fraktur", "geen scheur", "bez rupture", "den" (griego), "nyama" (búlgaro), "izlenmedi", entre otras).

d) Asigna cada término de lesión a la estructura anatómica más cercana en el texto, para no confundir, por ejemplo, "LCM íntegro, LCA roto".

e) Para la artrosis decide el compartimento (medial, lateral o patelofemoral) según la anatomía nombrada en la misma cláusula.

Como segunda fuente usamos una versión del archivo de etiquetas curada con apoyo de un modelo de lenguaje, aplicando una rúbrica basada en bibliografía (por ejemplo, la escala de Stoller para menisco y la definición de Hunter et al. (2011) para artrosis). Dejamos esto declarado de forma explícita porque no es código propio del grupo; el pipeline permite entrenar solo con las reglas cambiando un parámetro. Para estimar su ruido, aplicamos esa misma lectura a ciegas (sin ver las etiquetas) sobre los 58 reportes dorados: coincidió con el radiólogo en 82.3 % de las celdas, un nivel parecido al de las reglas.

Las dos fuentes se combinan en una **etiqueta suave** $\tilde{y}_{ij}$ con un peso de confianza w_{ij} para cada estudio i y hallazgo j:

$$\tilde{y}_{ij} = \tfrac{1}{2}\big(r_{ij} + c_{ij}\big), \qquad w_{ij} = \begin{cases} 1 & \text{si } r_{ij} = c_{ij} \\ 0.5 & \text{si } r_{ij} \neq c_{ij} \end{cases} \tag{1}$$

donde r_{ij} es la etiqueta de las reglas y c_{ij} la curada. Si las fuentes coinciden, la etiqueta vale 0 o 1 con peso completo; si discrepan, vale 0.5 con medio peso.

3.4. Arquitecturas

Las dos arquitecturas comparten la misma estructura. Cada triplete de cortes (corte anterior, actual y siguiente, como si fueran los tres canales de una imagen RGB) pasa por un extractor 2D. Esto da un

vector h_k por triplete. Luego un pooling por atención (Ilse et al., 2018) combina los $K = 11$ vectores del estudio:

$$a_k = \frac{\exp\big(v^\top \tanh(W h_k)\big)}{\sum_{l=1}^{K} \exp\big(v^\top \tanh(W h_l)\big)}, \qquad z = \sum_{k=1}^{K} a_k h_k, \tag{2}$$

y una capa lineal produce doce salidas sigmoides independientes. Los pesos a_k indican qué corte consideró más relevante el modelo, y los usamos para elegir el corte del Grad-CAM. Las diferencias entre ambas redes están en el extractor (Tabla 2).

Tabla 2: Flujo de datos de las dos arquitecturas (dimensiones por triplete, canales × alto × ancho).

Etapa	CNN desde cero	ResNet-50 preentrenada
Entrada	$3 \times 224 \times 224$	$3 \times 224 \times 224$
Bloque 1	$32 \times 112 \times 112$	
Bloque 2	$64 \times 56 \times 56$	Cuatro etapas residuales de
Bloque 3	$128 \times 28 \times 28$	ResNet-50 con pesos de Ima-
Bloque 4	$256 \times 14 \times 14$	geNet
Bloque 5	$512 \times 7 \times 7$	$2048 \times 7 \times 7$
Pooling promedio global	512	2048
Atención entre 11 cortes	$11 \times 512 \to 512$	$11 \times 2048 \to 2048$
Dropout (0.3) + lineal	12 sigmoides	12 sigmoides
Parámetros	4.8 millones	23.8 millones

Cada bloque de la CNN desde cero tiene dos convoluciones de 3×3 con BatchNorm y ReLU, seguidas de un MaxPool de 2×2.

3.5. Funciones de pérdida

La pérdida base es una entropía cruzada binaria (BCE) que acepta la etiqueta suave y pondera cada celda por su confianza:

$$\mathcal{L}_{BCE} = \frac{1}{\sum_{ij} w_{ij}} \sum_{i,j} w_{ij} \Big[-\alpha_j \tilde{y}_{ij} \log p_{ij} - (1 - \tilde{y}_{ij}) \log(1 - p_{ij}) \Big], \tag{3}$$

donde p_{ij} es la probabilidad predicha y $\alpha_j = 1$ salvo en la variante `pos_weight`. En esa variante, α_j es el cociente entre negativos y positivos del hallazgo j, acotado entre 1 y 10. La pérdida focal (Lin et al., 2017) multiplica cada término por $(1 - p_t)^\gamma$, con p_t la probabilidad asignada a la clase correcta y $\gamma = 2$.

3.6. Entrenamiento y experimentos

Entrenamos en Google Colab con una GPU Tesla T4 y precisión mixta. Los hiperparámetros comunes fueron:

- optimizador AdamW, tasa de aprendizaje de 3×10^{-4} con decaimiento coseno y *weight decay* de 10^{-4};
- lotes de 4 estudios y un máximo de 15 épocas;
- parada temprana con paciencia de 4 épocas sobre el AUC de la validación débil;
- aumento de datos con recorte aleatorio y variación de brillo y contraste. No volteamos las imágenes, porque eso cambiaría la anatomía.

Cada época tomó entre 19 y 29 segundos (sin contar la primera, que incluye la descarga de pesos). La Tabla 3 resume los experimentos. En la ablación de plano la red, los hiperparámetros y la muestra son los mismos; solo cambia la serie de entrada, que se elige con la misma regla (coronal sensible a líquido con supresión grasa si existe, si no cualquier coronal). Todos los estudios tienen serie coronal; en el conjunto dorado, 51 de los 53 la tienen con supresión grasa.

Tabla 3: Configuraciones experimentales. Todos se evalúan sobre los 53 estudios dorados.

Experimento	Arquitectura	Pérdida	Etiquetas / desbalance	Plano
Desde cero	CNN 2.5D propia	BCE	Etiqueta suave	Sagital
Base	ResNet-50	BCE	Etiqueta suave	Sagital
Ablación 1	ResNet-50	Focal ($\gamma = 2$)	Etiqueta suave	Sagital
Ablación 2	ResNet-50	BCE	Solo consenso	Sagital
Ablación 3	ResNet-50	BCE + `pos_weight`	Etiqueta suave	Sagital
Ablación 4	ResNet-50	BCE	Etiqueta suave	Coronal

3.7. Métricas de evaluación

La métrica principal es la oficial de la competencia: el AUC-ROC calculado para cada hallazgo y promediado sobre los doce, con igual peso. Para precisión, recall y F1 hace falta un umbral. Elegimos por cada hallazgo el umbral que maximiza el F1 en la validación débil, sin tocar los datos dorados, para no inflar los resultados. En la validación débil, una celda con etiqueta suave de 0.5 (fuentes en desacuerdo) se cuenta como positiva; es una decisión conservadora que favorece el recall. Como 53 estudios es una muestra pequeña, calculamos intervalos de confianza del 95 % con 2,000 remuestreos bootstrap sobre las predicciones guardadas. Comparamos los modelos de a pares sobre los mismos remuestreos.

4. Resultados

4.1. Calidad de las etiquetas débiles

La Tabla 4 compara las etiquetas del extractor por reglas con las 58 etiquetas doradas. El acuerdo global es de 80.9 %, es decir, cerca de **19 % de las celdas tienen ruido** respecto a lo que marcó el radiólogo. Los hallazgos con nombre claro y poco ambiguo en el texto (LCA, meniscos, quiste de Baker) salen bien, con kappa entre 0.71 y 0.79. Los peores son el derrame y la sinovitis (kappa de 0.31 y 0.32). Al revisar los casos vimos que el estándar dorado usa un criterio más amplio que la bibliografía estricta: marca sinovitis o derrame a partir de hallazgos indirectos, y cuenta la condropatía como artrosis. Entre las dos fuentes débiles, el desacuerdo sobre los 4,349 estudios sin etiqueta dorada fue de 6.3 % de las celdas, concentrado en artrosis (26.1 % en patelofemoral, 15.9 % en medial y 13.2 % en lateral).

Tabla 4: Extractor por reglas frente a la etiqueta dorada (58 estudios, solo texto).

Hallazgo	Positivos dorados	Acuerdo	F1	Kappa
LCA	24	0.897	0.889	0.794
LCM	9	0.845	0.609	0.518
Menisco medial	26	0.879	0.868	0.757
Menisco lateral	23	0.862	0.818	0.707
OA medial	15	0.845	0.710	0.604
OA lateral	11	0.776	0.519	0.379
OA patelofemoral	21	0.776	0.711	0.529
Derrame	35	0.707	0.800	0.310
Sinovitis	27	0.672	0.558	0.324
Quiste de Baker	12	0.897	0.786	0.719
Contusión	19	0.759	0.632	0.452
Fractura	18	0.793	0.700	0.545
Macro	240	**0.809**	**0.717**	**0.553**

4.2. Desbalance de clases

La Figura 2 muestra la prevalencia de cada hallazgo. En entrenamiento va de 12.2 % (fractura) a 63.5 % (derrame). El conjunto dorado tiene una distribución distinta: hay bastante más sinovitis (45.3 % contra 17.9 %), contusión (34.0 % contra 15.8 %) y fractura (32.1 % contra 12.2 %). Esto también es una fuente de diferencia entre entrenamiento y prueba. Como mitigación implementamos y evaluamos dos estrategias: la ponderación `pos_weight` y la pérdida focal (Sección 4.4).

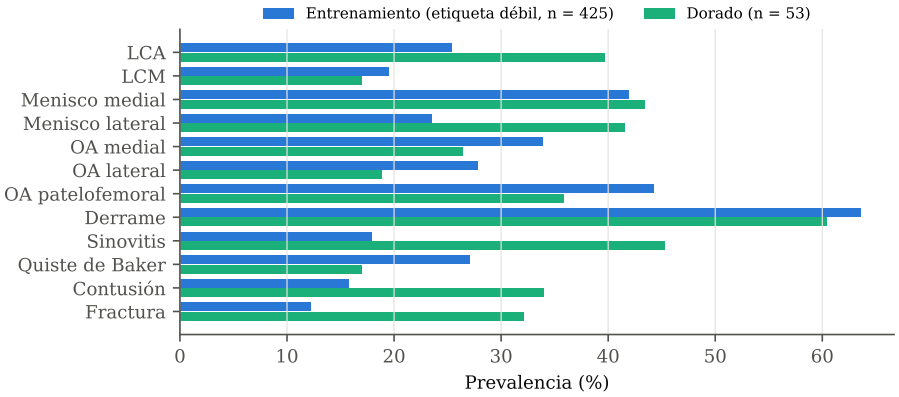


Figura 2: Prevalencia por hallazgo en la muestra de entrenamiento (etiqueta débil) y en el conjunto dorado (los 53 estudios evaluados con imagen).

4.3. Comparación de arquitecturas

La ResNet-50 preentrenada supera con claridad a la CNN desde cero (Tabla 5). El AUC macro pasa de 0.645 a 0.736, una diferencia de 0.091 con intervalo de confianza de 0.018 a 0.163. Como el intervalo no incluye el cero, la mejora no se explica por el azar de la muestra. La Figura 3a muestra por qué: la CNN desde cero apenas aprende (su AUC de validación débil se mueve entre 0.61 y 0.69, y la parada temprana la detuvo en la época 10), mientras que la ResNet-50 sube de forma sostenida hasta 0.794. Con 425 estudios y etiquetas con ruido, partir de pesos de ImageNet hace una diferencia grande, aunque las imágenes de RM se vean muy distintas a las fotos de ImageNet.

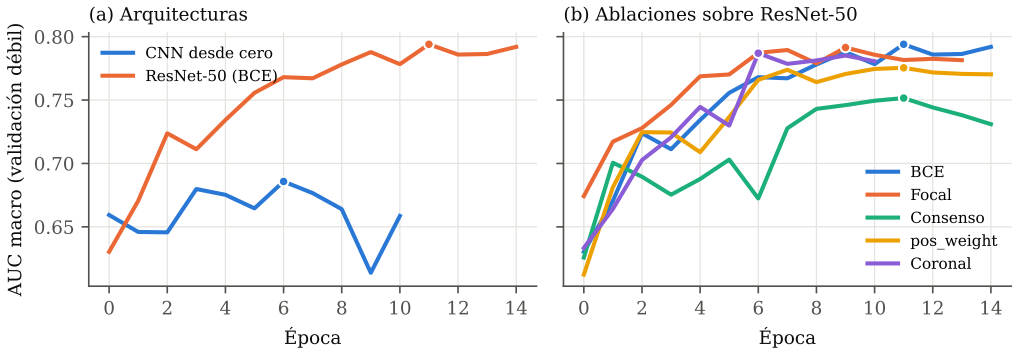


Figura 3: AUC macro en la validación débil por época. El punto marca la mejor época, que es el modelo que se guardó.

Por hallazgo (Figura 4), la ResNet-50 es mejor en 10 de los 12. Sus mejores resultados son OA medial (0.927), quiste de Baker (0.849) y derrame (0.795). Los más débiles son el LCM (0.616), con solo 9 positivos dorados, y el menisco lateral (0.620). La CNN desde cero queda en el nivel del azar

para la contusión (0.437) y el LCM (0.516), pero obtiene un AUC alto en OA lateral (0.900). Con solo 10 positivos en ese hallazgo, ese valor hay que tomarlo con cuidado.

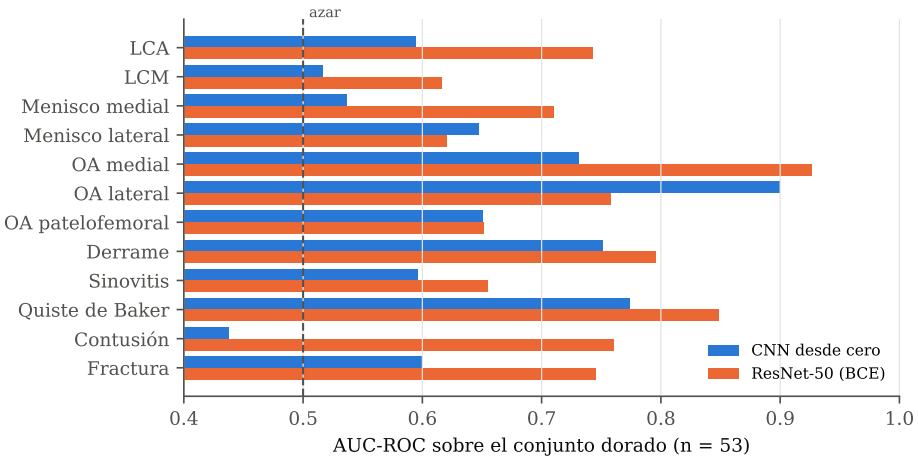


Figura 4: AUC-ROC por hallazgo sobre los 53 estudios dorados. La línea punteada marca el azar (0.5).

4.4. Estudio de ablación

Sobre la ResNet-50 evaluamos cuatro factores: la función de pérdida, el manejo de las etiquetas ruidosas, la ponderación por desbalance y el plano de la serie (Tabla 5). Ninguno cambia el AUC macro de forma significativa: todas las diferencias contra el modelo base tienen intervalos que incluyen el cero (las diferencias se expresan como base menos variante).

- **Pérdida focal**: AUC de 0.738 contra 0.736; diferencia de -0.002, IC -0.049 a 0.048.
- **Solo consenso** (las celdas en que las fuentes discrepan pesan 0): 0.721; diferencia de 0.015, IC -0.039 a 0.068.
- `pos_weight`: 0.717; diferencia de 0.019, IC -0.024 a 0.063.
- **Plano coronal**: 0.734; diferencia de 0.002, IC -0.052 a 0.053.

Donde sí hay diferencias es por hallazgo. La pérdida focal mejora el derrame (0.888 contra 0.795) y la sinovitis (0.723 contra 0.655), pero el recall de sinovitis con su umbral cae a 0.08. `pos_weight` ayuda a la OA patelofemoral (0.768 contra 0.652) y al menisco lateral (0.716 contra 0.620), pero empeora el quiste de Baker (0.634 contra 0.849) y el menisco medial (0.528 contra 0.710); es decir, mueve el problema de un hallazgo a otro. Entrenar solo con las celdas de consenso mejora el LCA (0.836) y la contusión (0.811), pero baja el menisco medial a 0.565. Nuestra lectura es que con 53 estudios de prueba no podemos declarar un ganador entre estas variantes. Sí podemos decir que la etiqueta suave con BCE es una opción razonable y estable.

Ablación de plano. El plano coronal da casi el mismo AUC macro que el sagital, pero gana en 6 de los 12 hallazgos y pierde en los otros 6. Mejora la sinovitis (0.703 contra 0.655, y su F1 sube de 0.303 a 0.537), la contusión (0.805 contra 0.760) y la fractura (0.801 contra 0.745). Empeora la OA medial (0.841 contra 0.927), el menisco lateral (0.576 contra 0.620) y la OA lateral (0.721 contra 0.758). Esperábamos que el coronal ayudara al LCM, porque ese ligamento se ve completo en ese plano, pero no fue así (0.596 contra 0.616); con solo 9 positivos dorados no podemos sacar una conclusión sobre ese hallazgo. Lo que sí muestra este resultado es que los dos planos aportan información distinta, lo que apoya combinarlos en un mismo modelo.

Con el umbral elegido (Tabla 6), el modelo base logra F1 macro de 0.551, con recall mayor que la precisión (0.667 contra 0.523). En un contexto de apoyo al radiólogo preferimos ese sesgo, porque es

Tabla 5: Resumen de resultados sobre los 53 estudios dorados. AUC macro con IC 95 % bootstrap; precisión, recall y F1 macro con el umbral elegido en la validación débil.

Experimento	AUC macro	IC 95 %	Precisión	Recall	F1
CNN desde cero (BCE)	0.645	0.582 a 0.701	0.409	0.703	0.494
ResNet-50 (BCE, base)	**0.736**	0.676 a 0.785	0.523	0.667	0.551
ResNet-50 + focal	**0.738**	0.678 a 0.789	0.474	0.637	0.512
ResNet-50 + solo consenso	0.721	0.653 a 0.775	0.491	0.626	0.509
ResNet-50 + `pos_weight`	0.717	0.658 a 0.768	0.499	0.724	0.558
ResNet-50 + plano coronal	0.734	0.679 a 0.780	0.470	0.748	0.546

Tabla 6: Métricas por hallazgo del modelo base (ResNet-50, BCE) sobre los 53 estudios dorados, con el umbral elegido en la validación débil.

Hallazgo	Umbral	Precisión	Recall	F1	AUC-ROC
LCA	0.30	0.567	0.810	0.667	0.743
LCM	0.10	0.182	0.889	0.302	0.616
Menisco medial	0.35	0.541	0.870	0.667	0.710
Menisco lateral	0.25	0.500	0.591	0.542	0.620
OA medial	0.50	0.750	0.643	0.692	0.927
OA lateral	0.25	0.333	0.600	0.429	0.758
OA patelofemoral	0.45	0.692	0.474	0.562	0.652
Derrame	0.45	0.640	1.000	0.780	0.795
Sinovitis	0.40	0.556	0.208	0.303	0.655
Quiste de Baker	0.40	0.500	0.556	0.526	0.849
Contusión	0.15	0.484	0.833	0.612	0.760
Fractura	0.20	0.529	0.529	0.529	0.745
Macro		0.523	0.667	0.551	0.736

peor dejar pasar una lesión que revisar un falso positivo. Los dos casos más problemáticos son la sinovitis, con recall de solo 0.208, y el LCM, con precisión de 0.182.

Mitigación del desbalance en los hallazgos raros. Los cuatro hallazgos menos frecuentes en entrenamiento son fractura (12.2 %), contusión (15.8 %), sinovitis (17.9 %) y LCM (19.5 %). La Tabla 7 compara las dos estrategias de mitigación en esos hallazgos. Ninguna gana en todos. `pos_weight` sube mucho el F1 de la sinovitis (de 0.303 a 0.545) porque recupera casos positivos (recall de 0.208 a 0.500), y mejora un poco el AUC del LCM. La pérdida focal mejora el AUC de contusión y sinovitis, pero empeora fractura y LCM. Con tan pocos positivos dorados (entre 9 y 24) estas diferencias son orientativas.

Tabla 7: Hallazgos raros: AUC-ROC y F1 (entre paréntesis) con cada estrategia de mitigación.

Hallazgo (positivos dorados)	Base (BCE)	Focal	`pos_weight`
Fractura (17)	**0.745** (0.529)	0.703 (0.474)	0.737 (0.483)
Contusión (18)	0.760 (0.612)	**0.787** (0.634)	0.779 (0.605)
Sinovitis (24)	0.655 (0.303)	**0.723** (0.143)	0.687 (**0.545**)
LCM (9)	0.616 (0.302)	0.548 (0.229)	**0.639** (0.310)

4.5. Interpretabilidad con Grad-CAM

Generamos mapas Grad-CAM para cuatro hallazgos (LCA, menisco medial, derrame y quiste de Baker) en los tres estudios dorados positivos con mayor probabilidad, sobre el corte con más peso de atención. En los casos mostrados, la parte anterior de la rodilla (rótula) queda a la izquierda.

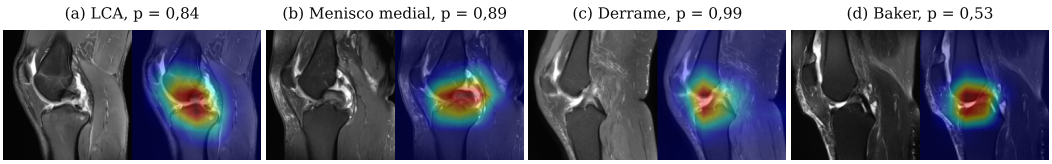


Figura 5: Grad-CAM de la ResNet-50 para cuatro hallazgos (imagen original y mapa superpuesto). En los cuatro casos el mapa se concentra en el centro de la articulación.

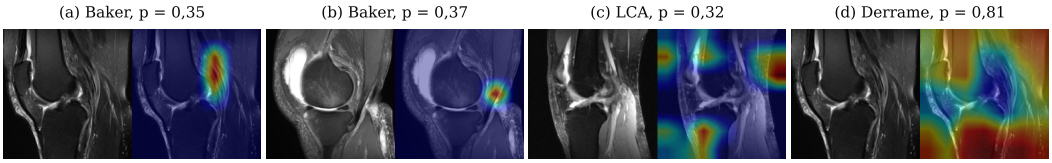


Figura 6: Grad-CAM de la CNN desde cero. Para el quiste de Baker (a, b) el mapa cae en la región posterior; para el LCA (c) cae en los bordes de la imagen.

El resultado es mixto y lo reportamos tal cual:

- En la **ResNet-50** (Figura 5), los mapas de los cuatro hallazgos se parecen mucho entre sí: todos marcan la zona central de la articulación, entre el fémur y la tibia. Para el **LCA** esto es anatómicamente plausible, porque el ligamento está en la escotadura intercondílea. Para el **menisco** es plausible a medias: marca la línea articular, aunque en un corte central y no sobre los cuernos meniscales. Para el **derrame**, que debería verse en el receso suprapatelar (arriba y adelante), y para el **quiste de Baker**, que está en la fosa poplítea (atrás), **no es plausible**. Nuestra hipótesis es que el modelo aprendió un patrón general de "rodilla con patología" en el centro de la articulación y lo comparte entre hallazgos que suelen aparecer juntos. A eso se suma que el mapa de la última capa tiene apenas 7×7 posiciones.
- En la **CNN desde cero** (Figura 6), los mapas varían más. Para el **quiste de Baker** caen en la región posterior, en dos de los tres casos, donde está el quiste. Para el **LCA** caen en los bordes de la imagen, lejos del ligamento, lo que sugiere que el modelo usa atajos sin sentido anatómico. Esto concuerda con su AUC bajo para ese hallazgo (0.595).

5. Discusión: sesgo geográfico y lingüístico

Los datos vienen de 16 centros en cinco continentes y los reportes están escritos en varios idiomas. Nuestro extractor depende de listas de palabras y de patrones de negación que armamos para cada idioma. Por eso su calidad no es la misma en todos: está más trabajado en inglés y castellano, que son los idiomas que más aparecen y que mejor revisamos, que en griego, búlgaro o turco. Además, el conjunto dorado no permite medir esa diferencia. De los 58 estudios, 30 están en inglés, 8 en castellano, 6 en turco, 4 en croata, 3 en griego, 3 en búlgaro, 2 en neerlandés y 2 en alemán; con dos o tres casos por idioma no se puede estimar el ruido de forma separada.

La consecuencia es que los estudios de algunos centros entran al entrenamiento con etiquetas peores, y el modelo puede aprender peor justo esas poblaciones, sin que el AUC global lo muestre. A eso

se suman diferencias reales entre centros: el equipo (fabricante, 1.5 o 3 teslas), el protocolo y la forma de redactar. Por ejemplo, unos radiólogos gradúan la lesión meniscal con números y otros la describen con palabras. En un despliegue clínico real, un modelo así podría funcionar bien en el hospital que más se parece a los datos de entrenamiento y mal en otro, y nadie se daría cuenta hasta tener errores. Antes de usarlo en un centro nuevo habría que validarlo con casos etiquetados de ese centro, reportar las métricas por centro e idioma, y revisar a mano una muestra de las etiquetas que el extractor genera para cada idioma.

6. Conclusiones

6.1. Principales hallazgos

- **Las etiquetas débiles sirven, pero con ruido medible.** El extractor multilingüe por reglas coincide con el radiólogo en 80.9 % de las celdas (kappa de 0.553). Es suficiente para entrenar un modelo útil, aunque el derrame y la sinovitis quedan con mucho ruido.
- **El preentrenamiento es lo que más pesa.** La ResNet-50 con pesos de ImageNet supera a la CNN desde cero por 0.091 de AUC macro (0.736 contra 0.645), una diferencia significativa incluso con solo 53 estudios de prueba.
- **Las ablaciones no cambian el promedio, pero sí la distribución por hallazgo.** La pérdida focal, el entrenamiento solo con consenso, `pos_weight` y el plano coronal quedan dentro del margen de error en el AUC macro, pero mejoran unos hallazgos a costa de otros. El coronal, en particular, mejora sinovitis, contusión y fractura, y pierde en artrosis medial y lateral.
- **La interpretabilidad pone un límite.** Los mapas Grad-CAM de la ResNet-50 son plausibles para el LCA, pero no para el derrame ni el quiste de Baker. Eso indica que el modelo todavía no localiza bien cada hallazgo, aunque los clasifique mejor que el azar.

6.2. Limitaciones

- Evaluamos sobre 53 estudios dorados (5 no estaban en nuestra copia local), con pocos positivos en algunos hallazgos (9 en LCM y en quiste de Baker). Los intervalos de confianza son anchos.
- Las etiquetas de entrenamiento tienen cerca de 19 % de ruido respecto al estándar dorado, y parte de ese ruido viene de que el radiólogo usó un criterio más amplio que la bibliografía.
- Una de las dos fuentes de etiquetas débiles fue curada con apoyo de un modelo de lenguaje; lo declaramos y el código permite prescindir de ella.
- Cada modelo usa un solo plano. La ablación comparó sagital contra coronal por separado; no probamos un modelo que use los dos a la vez.
- El entrenamiento fue corto (como máximo 15 épocas en una GPU T4), sin búsqueda de hiperparámetros.
- No normalizamos la orientación dentro del corte ni el lado de la rodilla (derecha o izquierda). El modelo no depende del orden de los cortes gracias al pooling por atención, pero la variación de orientación entre centros puede afectar el aprendizaje y la lectura de los mapas Grad-CAM.
- Los intervalos de confianza y las figuras se calcularon después del entrenamiento, a partir de las predicciones guardadas, con el script `05_analisis_informe.py`.

6.3. Trabajo futuro

- Combinar los planos sagital y coronal en un mismo modelo.
- Usar mapas de mayor resolución para Grad-CAM, por ejemplo de la tercera etapa de la ResNet.
- Reemplazar el extractor por reglas con un clasificador de texto multilingüe entrenado sobre las etiquetas doradas y validado por idioma.

- Calibrar las probabilidades antes de fijar los umbrales clínicos.

7. Material complementario

El código reproducible (selección de estudios, preprocesamiento DICOM, entrenamiento, evaluación y Grad-CAM) se encuentra en el repositorio de GitHub: `https://github.com/dfranco79/redes_neuronales_examen_parcial_grupo05`. Para reproducir los resultados recomendamos leer primero el archivo `README.md` del repositorio, que explica paso a paso la ejecución en dos partes: la parte local (pasos 01 y 02, que seleccionan los estudios y convierten los DICOM en volúmenes compactos para los planos sagital y coronal) y la parte en Google Colab (pasos 03 a 05, que entrenan, evalúan y generan los Grad-CAM, los intervalos de confianza y las figuras). En Colab el flujo completo se ejecuta con un solo comando, `bash ejecutar_colab.sh`; el `README.md` también indica cómo correr un solo experimento sin repetir todo.

Declaración de uso de IA. Usamos un asistente de IA para apoyar la curación de una de las fuentes de etiquetas débiles y la redacción de partes del código y del informe. Las decisiones de diseño, la ejecución de los experimentos y el análisis de resultados fueron revisados por el grupo.

Referencias

N. Bien, P. Rajpurkar, R. L. Ball, J. Irvin, A. Park, E. Jones, et al. Deep-learning-assisted diagnosis for knee magnetic resonance imaging: development and retrospective validation of MRNet. *PLoS Medicine*, 15(11):e1002699, 2018.

W. W. Chapman, W. Bridewell, P. Hanbury, G. F. Cooper, and B. G. Buchanan. A simple algorithm for identifying negated findings and diseases in discharge summaries. *Journal of Biomedical Informatics*, 34(5):301–310, 2001.

J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei. ImageNet: A large-scale hierarchical image database. In *IEEE CVPR*, 2009.

K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. In *IEEE CVPR*, pages 770–778, 2016.

D. J. Hunter, N. Arden, P. G. Conaghan, F. Eckstein, G. Gold, A. Grainger, et al. Definition of osteoarthritis on MRI: results of a Delphi exercise. *Osteoarthritis and Cartilage*, 19(8):963–969, 2011.

M. Ilse, J. M. Tomczak, and M. Welling. Attention-based deep multiple instance learning. In *International Conference on Machine Learning (ICML)*, 2018.

J. Irvin, P. Rajpurkar, M. Ko, Y. Yu, S. Ciurea-Ilcus, C. Chute, et al. CheXpert: A large chest radiograph dataset with uncertainty labels and expert comparison. In *AAAI Conference on Artificial Intelligence*, 2019.

T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár. Focal loss for dense object detection. In *IEEE ICCV*, 2017.

A. Ratner, S. H. Bach, H. Ehrenberg, J. Fries, S. Wu, and C. Ré. Snorkel: Rapid training data creation with weak supervision. *Proceedings of the VLDB Endowment*, 11(3):269–282, 2017.

Radiological Society of North America. RSNA Knee Abnormality Detection. Competencia de Kaggle, 2026. `https://www.kaggle.com/competitions/rsna-knee-abnormality-detection`.

R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra. Grad-CAM: Visual explanations from deep networks via gradient-based localization. In *IEEE ICCV*, 2017.