Mapeo de Inundaciones con Radar Sentinel-1 y una U-Net Entrenada desde Cero: Etiquetas Débiles, Pérdidas y Generalización Geográfica

Guillermo Cajo gcajos@uni.pe
Andre Carasas andre.carasas.o@uni.pe
Daniel Franco daniel.franco.s@uni.pe
Ivonne Lazo ivonne.lazo.g@uni.pe
David Grabiel david.grabiel.g@uni.pe
Joel Renojo joel.renojo.c@uni.pe

FIIS, Universidad Nacional de Ingeniería (UNI), Lima, Perú

Resumen

Las nubes que acompañan a las tormentas dejan sin uso a los satélites ópticos justo cuando más se necesitan, pero el radar de apertura sintética (SAR) de Sentinel-1 puede ver a través de ellas. En este trabajo entrenamos desde cero una U-Net en PyTorch para segmentar el agua de inundación píxel a píxel en Sen1Floods11 usando las bandas VV y VH. Estudiamos cómo combinar los 446 chips etiquetados a mano con miles de etiquetas débiles obtenidas por umbralización, comparamos tres funciones de pérdida y medimos la generalización a un evento no visto (Bolivia). El modelo final, Dorados + débiles S2 (índice), obtiene IoU = 0.669 y F1 = 0.802 en el test, e IoU = 0.664 en Bolivia. También analizamos los errores típicos del SAR (sombra de radar, doble rebote y bordes con suelo húmedo) usando reglas físicas simples.

1 Motivación

Durante una inundación es clave saber dónde está el agua en las primeras horas para evacuar, llevar ayuda y estimar daños. En el Perú, eventos como El Niño costero causan inundaciones repentinas que hay que mapear con las primeras imágenes disponibles. Los sensores ópticos no ven a través de las nubes de la tormenta, mientras que el radar de apertura sintética (SAR) de Sentinel-1 toma imágenes de día y de noche aunque esté nublado. En SAR el agua abierta se ve oscura porque refleja el pulso lejos del sensor, pero la sombra de radar, las superficies lisas, el doble rebote en zonas urbanas y la vegetación inundada rompen esa regla.

En este trabajo entrenamos una U-Net propia sobre Sen1Floods11 para responder tres preguntas: (i) cómo combinar pocas etiquetas manuales con muchas etiquetas automáticas pero ruidosas, (ii) qué función de pérdida conviene con un desbalance de clases tan fuerte y (iii) cuánto empeora el modelo en un evento que no vio durante el entrenamiento.

2 Trabajos Relacionados

Umbralización clásica. El agua abierta refleja el pulso del radar de forma especular y por eso se ve oscura en las imágenes SAR. Los métodos operativos aprovechan esto y umbralizan la retrodispersión, muchas veces con el método de Otsu (1979), aplicado por bloques (Martinis et al., 2009) o dentro de cadenas automáticas para Sentinel-1 (Twele et al., 2016). Son rápidos y no necesitan etiquetas,

pero fallan en sombras de radar, superficies lisas, zonas urbanas y vegetación inundada. Las etiquetas débiles de Sen1Floods11 se generaron justamente con este tipo de umbralización.

Segmentación con redes convolucionales. La U-Net (Ronneberger et al., 2015) combina un codificador que captura el contexto con un decodificador que recupera el detalle espacial gracias a las conexiones de salto, y es la arquitectura de referencia en segmentación. Variantes como Attention U-Net (Oktay et al., 2018) y UNet++ (Zhou et al., 2018) modifican esas conexiones. Para clases desbalanceadas, la pérdida Dice (Milletari et al., 2016) optimiza directamente el solapamiento. Como optimizador usamos AdamW (Loshchilov and Hutter, 2019), que separa el decaimiento de pesos de la actualización del gradiente.

Aprendizaje profundo para inundaciones. Sen1Floods11 (Bonafilia et al., 2020) publica 446 chips etiquetados a mano y 4,385 con etiquetas automáticas de 11 eventos, y muestra que las redes superan a la umbralización y que generalizar a un evento no visto (Bolivia) es la parte difícil. Konapala et al. (2021) estudian la combinación de Sentinel-1 y Sentinel-2 en este mismo dataset, y Mateo-Garcia et al. (2021) entrenan modelos globales de detección de agua con etiquetas imperfectas a gran escala.

3 Metodología

3.1 Datos: inventario de Sen1Floods11

Antes de entrenar comparamos las características del dataset que da el enunciado con lo que se encontró al descargar los datos del bucket público `gs://sen1floods11` (versión 1.1). La Tabla 1 resume la comparación.

Tabla 1: Características del dataset: enunciado vs. datos descargados.

Característica	Enunciado	Encontrado	Estado
Eventos de inundación (chips dorados)	11	11: Bolivia, Ghana, India, Mekong, Nigeria, Pakistan, Paraguay, Somalia, Spain, Sri-Lanka, USA	✓
Bandas Sentinel-1	VV y VH, en dB	2 bandas (VV, VH), float32 en dB, VV mediano -11.7 dB	✓
Bandas Sentinel-2	13 bandas espectrales	13 bandas (B1 a B12, incluye B8A), reflectancia TOA $\times$ 10000	✓
Tamaño y resolución	512×512 px a 10 m, GeoTIFF	512×512 px, píxel de 10.0 m (EPSG:4326), GeoTIFF	✓
Chips con etiqueta dorada	446	446 en el bucket, 446 usados (train 252, valid 89, test 90, Bolivia 15)	✓
Valores de la máscara dorada	agua / no agua / sin datos	$\{-1, 0, 1\}$ (1 agua, 0 no agua, -1 sin datos)	✓
Chips débiles de Sentinel-1 (Otsu)	4,385	4,384 GeoTIFF en el bucket (la metadata oficial suma 4,384); 4,160 usados	$\approx$
Chips débiles de Sentinel-2 (índice)	4,385	4,384 GeoTIFF en el bucket (+1 archivo no imagen: .DS_Store); 4,160 usados	$\approx$
Imágenes S2 de los chips débiles (S2Weak)	no lo pide ningún entregable	4,384 en el bucket (25.7 GB); no se descargan porque los modelos con débiles usan SAR como entrada	–
Débiles excluidos por ser de Bolivia	necesario para el entregable 4	224	✓
Bolivia como prueba independiente	todos los chips dorados de Bolivia	15 de 15 chips dorados de Bolivia en el split de prueba; 0 en train/valid	✓
Métrica de referencia	IoU promedio sobre los chips + omisión y comisión	se reportan (además de IoU agregado, F1, precisión y recall)	✓

Número de chips débiles. El enunciado y el artículo original hablan de 4,385 chips débiles, pero el bucket v1.1 tiene 4,384 GeoTIFF en cada carpeta de chips débiles, lo mismo que suma la metadata

oficial del dataset (4,384). La carpeta de etiquetas de Sentinel-2 tiene 4,385 objetos, pero 1 no es una imagen (.DS_Store). Se usan todos los chips débiles disponibles menos los de Bolivia.

Los chips dorados cubren 11 eventos y suman 446; de los 4,384 chips débiles del bucket se usan 4,160. Colombia solo tiene chips débiles. Los chips débiles de Bolivia se dejan fuera para que el entregable 4 mida la generalización a un evento que el modelo de verdad no vio (Figura 1).

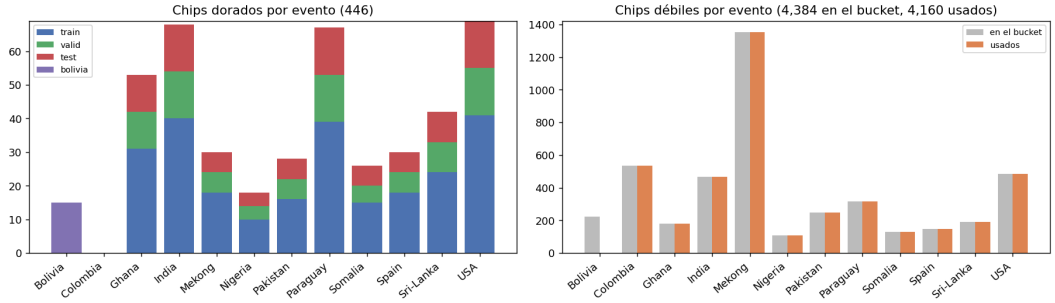


Figura 1: Chips dorados por evento y partición (izquierda) y chips débiles por evento (derecha).

Usamos la partición oficial: 252 chips dorados de entrenamiento, 89 de validación, 90 de test (eventos vistos) y 15 de Bolivia (evento reservado). Para el entregable 2a se usan 4,160 chips débiles con etiqueta Otsu de Sentinel-1 y 4,160 con etiqueta por índice espectral de Sentinel-2, que son las dos fuentes de etiquetas débiles del dataset.

3.2 Ruido de las etiquetas débiles

El dataset también trae la etiqueta Otsu de los chips dorados (S1OtsuLabelHand), así que se puede comparar directamente con la etiqueta manual: IoU = 0.485, precisión = 0.609 y recall = 0.704 en 431 chips (coinciden en el 92.2 % de los píxeles). En otras palabras, la umbralización marca más agua de la que realmente hay (más comisión que omisión). El ruido cambia bastante entre eventos: el peor es Somalia (IoU 0.151) y el mejor Mekong (IoU 0.780). Las etiquetas débiles son muchas pero imperfectas, y eso es lo que se pone a prueba en el entregable 2a. Para las etiquetas débiles de Sentinel-2 el dataset no trae una versión sobre los chips dorados, así que su calidad solo se puede ver de forma indirecta en los resultados del 2a.

3.3 U-Net propia

La U-Net está escrita desde cero en PyTorch, sin librerías de segmentación (clases `DoubleConv`, `Down`, `Up` y `UNet`). Cada bloque aplica dos veces convolución 3×3, BatchNorm y ReLU. El codificador tiene 4 niveles de submuestreo (MaxPool 2×2) con 32, 64, 128, 256 y 512 canales; el decodificador hace un sobremuestreo bilineal $\times 2$, concatena la conexión de salto del mismo nivel y aplica otro bloque doble. Una convolución 1×1 produce un logit de agua por píxel. En total tiene 7.85 M de parámetros (el flujo de dimensiones está en la Tabla 8 del apéndice). Como entrada usa VV y VH en dB: los valores sin dato se reemplazan por -50 dB, se recorta a $[-50, 1]$ dB y se escala a $[0, 1]$.

3.4 Funciones de pérdida y entrenamiento

Sea p_i la probabilidad de agua del píxel i, $y_i \in \{0, 1\}$ su etiqueta y $\mathcal{V}$ el conjunto de píxeles válidos (con dato SAR y etiqueta distinta de -1). Las pérdidas comparadas son

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{|\mathcal{V}|} \sum_{i \in \mathcal{V}} \big[w\, y_i \log p_i + (1 - y_i) \log(1 - p_i) \big], \tag{1}$$

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2 \sum_{i \in \mathcal{V}} p_i y_i + 1}{\sum_{i \in \mathcal{V}} p_i + \sum_{i \in \mathcal{V}} y_i + 1}, \tag{2}$$

con $w = 3$ (`pos_weight`) para compensar el desbalance; la Dice se calcula por imagen y se promedia en el batch, y la pérdida combinada es $\mathcal{L}_{\text{BCE}} + \mathcal{L}_{\text{Dice}}$. Los píxeles sin dato no cuentan ni en

la pérdida ni en las métricas.

Se entrena con recortes aleatorios de 256×256 px a resolución nativa (10 m), volteos y rotaciones de 90°, y se evalúa sobre el chip completo de 512×512 (la red es totalmente convolucional). Optimizador AdamW (lr = 0.001, weight decay = 0.0001) con cosine annealing, 40 épocas por modelo, batch de 8, precisión mixta y semilla 42. De cada modelo se guarda la época con mayor IoU en la validación dorada, y el umbral de decisión se elige maximizando F1 en validación; el test y Bolivia solo se usan para reportar. El modelo final es el de mayor IoU en validación: **Dorados + débiles S2 (índice)**. La Figura 2 muestra las curvas de entrenamiento.

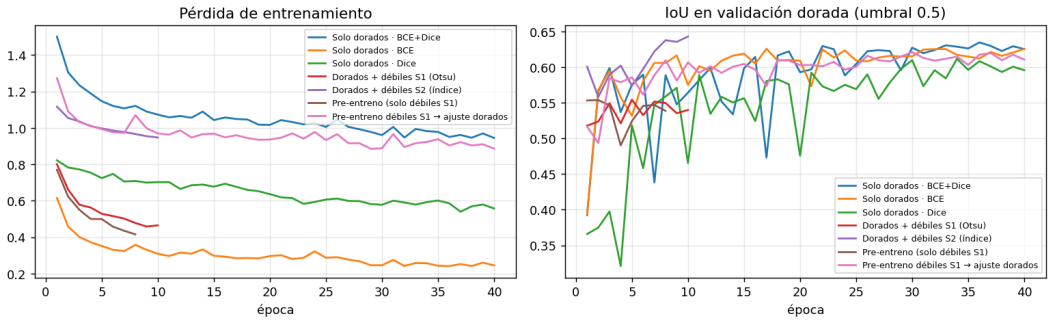


Figura 2: Curvas de entrenamiento: pérdida y IoU de validación por época de cada modelo.

4 Experimentos y Resultados

4.1 Solo dorados vs. dorados + débiles

Todas las estrategias usan la misma U-Net y la pérdida BCE+Dice, y se validan y evalúan solo con chips dorados: (1) solo los chips dorados de entrenamiento; (2) dorados + 4,160 chips débiles con etiqueta Otsu de Sentinel-1; (3) dorados + 4,160 chips débiles con etiqueta por índice de Sentinel-2; (4) pre-entrenamiento con los débiles S1 y ajuste final con los dorados. Con los débiles cada época tiene $\sim$4,412 chips, por eso estos modelos se entrenan 10 épocas en lugar de 40 (aun así hacen más pasos de optimización). La Tabla 2 resume los resultados (gráfico en la Figura 11 del apéndice).

Tabla 2: Estrategias de supervisión evaluadas en el test (eventos vistos).

Modelo	Umbral	IoU	IoU medio/chip	F1	Precisión	Recall	Omisión	Comisión
Solo dorados · BCE+Dice	0.55	0.654	0.413	0.790	0.784	0.797	0.203	0.216
Dorados + débiles S1 (Otsu)	0.20	0.604	0.332	0.753	0.755	0.751	0.249	0.245
Dorados + débiles S2 (índice)	0.45	**0.669**	**0.421**	**0.802**	0.778	0.828	0.172	0.222
Pre-entreno débiles S1 → ajuste dorados	0.55	0.647	0.391	0.786	0.769	0.803	0.197	0.231

- **Dorados + débiles S1 (Otsu)** frente a solo dorados: ΔIoU test -0.050, ΔIoU Bolivia $+0.124$, IoU de validación 0.557 (solo dorados: 0.635).
- **Dorados + débiles S2 (índice)** frente a solo dorados: ΔIoU test $+0.016$, ΔIoU Bolivia $+0.082$, IoU de validación 0.644 (solo dorados: 0.635).
- **Pre-entreno débiles S1 $\rightarrow$ ajuste dorados** frente a solo dorados: ΔIoU test -0.007, ΔIoU Bolivia $+0.077$, IoU de validación 0.623 (solo dorados: 0.635).

Según la validación, la mejor estrategia es **Dorados + débiles S2 (índice)**. Las etiquetas débiles S1 tienen en promedio 16.5 % de agua (S2: 13.5 %) y la etiqueta Otsu tiene un IoU de 0.485 frente a la etiqueta manual: aportan muchos más ejemplos y más variedad de eventos, pero con errores sistemáticos en bordes, sombras y vegetación. De las dos fuentes de etiquetas débiles, las **débiles S2 (índice)** dan mejor resultado en validación (0.557 S1 vs. 0.644 S2). Una explicación es que las etiquetas S1 salen del mismo radar y heredan sus errores (sombras, doble rebote), que el modelo termina aprendiendo; las S2 no dependen del radar, aunque sí de que la escena óptica esté despejada

y de que su fecha coincida con la del SAR. La idea del pre-entrenamiento con ajuste es aprovechar la cantidad de datos débiles para aprender patrones generales de retrodispersión y dejar que al final las etiquetas manuales corrijan los sesgos de la umbralización; al mezclarlos con los dorados, en cambio, el modelo ve ese ruido durante todo el entrenamiento. En nuestros resultados la supervisión débil **mejora** al modelo que solo usa chips dorados, así que vale la pena usarla.

4.2 BCE vs. Dice vs. BCE+Dice

La Tabla 3 compara las tres pérdidas con los mismos chips dorados, la misma arquitectura y las mismas épocas (gráfico en la Figura 12 del apéndice).

Tabla 3: Comparación de pérdidas (solo chips dorados, mismas épocas; umbral elegido en validación).

Modelo	Umbral	IoU	IoU medio/chip	F1	Precisión	Recall	Omisión	Comisión
Solo dorados · BCE	0.55	0.662	0.386	0.796	0.784	0.808	0.192	0.216
Solo dorados · Dice	0.10	0.640	0.385	0.780	0.765	0.797	0.203	0.235
Solo dorados · BCE+Dice	0.55	0.654	0.413	0.790	0.784	0.797	0.203	0.216

En validación, que es el criterio de selección, gana **Solo dorados · BCE+Dice** (IoU 0.635); en test el mejor es **Solo dorados · BCE** (IoU 0.662). La BCE con `pos_weight` = 3.0 logra precisión 0.784 y recall 0.808, y la Dice 0.765 y 0.797. La BCE promedia el error de todos los píxeles y, como hay ∼8 píxeles válidos por cada píxel de agua, sin el `pos_weight` su gradiente quedaría dominado por la tierra. La Dice mide directamente el solapamiento de la clase agua y no depende de los verdaderos negativos, así que en principio maneja mejor el desbalance. La combinación busca juntar el gradiente estable de la BCE con el enfoque en el solapamiento de la Dice.

4.3 Evaluación en distribución (test, eventos vistos)

La Tabla 4 reporta las métricas de la clase agua del modelo final en los 90 chips de test; la Figura 3 muestra cómo se eligió el umbral y la Figura 4 la matriz de confusión.

Tabla 4: Métricas de la clase agua en test del modelo final (umbral 0.45).

Modelo	Umbral	IoU	IoU medio/chip	F1	Precisión	Recall	Omisión	Comisión
Dorados + débiles S2 (índice)	0.45	0.669	0.421	0.802	0.778	0.828	0.172	0.222

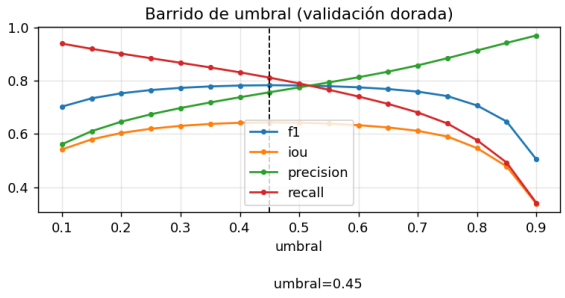


Figura 3: Barrido del umbral de decisión en validación; la línea discontinua marca el umbral elegido.

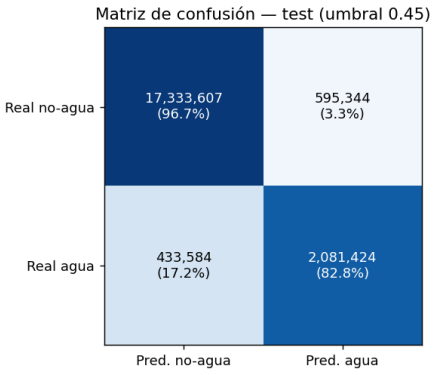


Figura 4: Matriz de confusión por píxel en el test (conteos y porcentaje por fila).

Comentario de la matriz de confusión. El agua es solo el 12.3 % de los 20,443,959 píxeles válidos del test, así que la exactitud no dice mucho: un modelo que nunca predijera agua tendría 87.7 % de exactitud (el nuestro tiene 95.0 %). Por eso usamos métricas de la clase agua. De cada 100 píxeles de agua real el modelo detecta 83 y se le escapan 17; de cada 100 píxeles que marca como agua, 78 lo son. Hay 0.29 falsos positivos por cada verdadero positivo y la **comisión** (falsas alarmas) es mayor

que la omisión, así que el modelo tiende a marcar agua de más. El IoU agregado es 0.669 (IC 95 % por bootstrap sobre chips: 0.562–0.749) y el IoU promedio por chip es 0.421: la diferencia indica que al modelo le va bien en los chips con mucha agua y peor en los que tienen poca, que en el promedio por chip pesan lo mismo.

Por evento, el más difícil es **Pakistan** (IoU 0.260) y el más fácil **Nigeria** (IoU 0.886); el desglose completo está en la Tabla 9 y hay ejemplos visuales en la Figura 13 del apéndice.

4.4 Generalización geográfica (Bolivia)

Siguiendo la partición oficial, ningún chip de Bolivia (dorado o débil) se usó para entrenar ni para elegir hiperparámetros. La Tabla 5 compara el modelo final en test y en Bolivia, y la Figura 5 lo hace para todos los modelos.

Tabla 5: Brecha de generalización del modelo final, Dorados + débiles S2 (índice).

Métrica	Test	Bolivia	Brecha
IoU	0.669	0.664	-0.005
IoU medio/chip	0.421	0.427	$+0.006$
F1	0.802	0.798	-0.004
Precisión	0.778	0.838	$+0.061$
Recall	0.828	0.762	-0.066

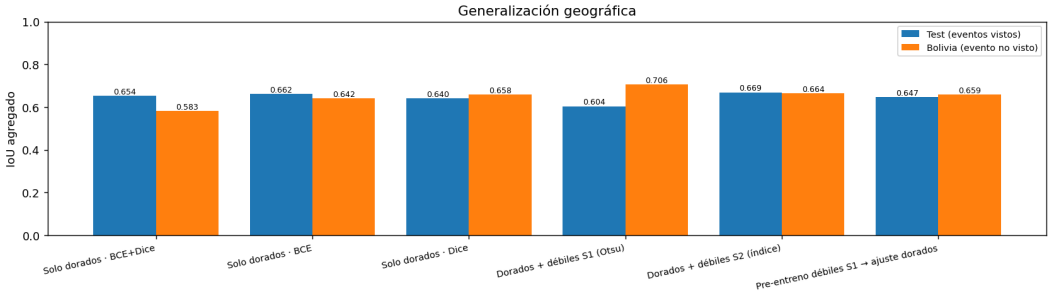


Figura 5: IoU en test (eventos vistos) y en Bolivia (evento no visto) de todos los modelos.

El IoU en Bolivia es 0.664 (IC 95 %: 0.477–0.775) y en el test 0.669, una brecha de -0.005. Los intervalos de confianza se solapan, así que con solo 15 chips la diferencia no es estadísticamente concluyente. En la práctica el modelo rinde igual en Bolivia que en los eventos vistos, aunque nunca vio esa zona al entrenar. Lo que sí cambia es el tipo de error: en Bolivia la precisión sube (+0.061) y el recall baja (-0.066), es decir, el modelo da menos falsas alarmas pero deja escapar más agua. La Tabla 6 reúne los datos con los que revisamos las hipótesis.

Tabla 6: Composición del test y de Bolivia (datos para revisar las hipótesis).

Conjunto	Chips	Eventos	Frac. agua	Chips sin agua	VV agua	VV tierra	Contraste	Agua brillante
Test	90	10	12.3 %	8	-17.6 dB	-9.5 dB	8.1 dB	25.7 %
Bolivia	15	1	16.0 %	0	-16.5 dB	-8.4 dB	8.1 dB	13.3 %

Hipótesis sobre la brecha, cada una comparada con los datos de la Tabla 6:

- **Composición y tamaño de los cuerpos de agua.** Fracción de agua: test 12.3 % vs. Bolivia 16.0 %; chips sin agua: 8 vs. 0. Las superficies de agua grandes y continuas (como las llanuras inundadas de la Amazonía boliviana) son más fáciles de segmentar que los parches pequeños, porque los errores de borde pesan menos frente al área total; y en un chip sin agua solo se pueden cometer falsas alarmas. Este factor favorece a Bolivia y puede compensar que sea un evento nuevo.

- **Contraste radiométrico.** Diferencia mediana de VV entre tierra y agua: 8.1 dB en test vs. 8.1 dB en Bolivia. Con más contraste, el agua (lisa y oscura) se separa mejor de la tierra (más brillante). La diferencia es pequeña, así que este factor por sí solo no explica la brecha.

- **Cobertura del suelo: zonas urbanas y vegetación inundada.** Porcentaje del agua con VV > -12 dB (agua "brillante", típica del doble rebote en ciudades o con vegetación que sobresale): test 25.7 % vs. Bolivia 13.3 %. Esa agua es casi invisible para un modelo que se basa en la retrodispersión. Este factor favorece a Bolivia y puede compensar que sea un evento nuevo. El evento más difícil del test es Pakistan (IoU 0.260).

- **Geometría de adquisición y ángulo de incidencia.** La escena de Bolivia es de órbita descendente (órbita relativa 156). El ángulo de incidencia cambia a lo ancho del swath de Sentinel-1 y modifica la retrodispersión de la tierra y del agua, así que el umbral que el modelo aprende en otros eventos puede encajar mejor o peor en una escena nueva. Los chips no traen el ángulo, por lo que no se puede comprobar aquí; habría que agregarlo como canal de entrada.

- **Varianza por tamaño de muestra.** Bolivia tiene solo 15 chips; el IC bootstrap (0.477–0.775) muestra cuánto puede moverse la métrica según qué chips entren.

4.5 Errores característicos del SAR

Cada píxel mal clasificado del test se asignó a un tipo de error con reglas simples sobre VV y la distancia al agua: FP oscuros (VV < -15 dB) a más de 50 m del agua real (sombra de radar o superficies muy lisas), FP en la franja de 50 m alrededor del agua (suelo saturado y píxeles mixtos), FN brillantes (VV > -12 dB: doble rebote en zonas urbanas o vegetación inundada), FN dentro del agua con VV intermedio (-16 a -12 dB: agua rugosa por viento o con sedimentos) y FN dentro del agua con VV oscuro (el agua tiene su firma típica pero el modelo no la marca, por ejemplo en cuerpos de agua muy pequeños o aislados). La Figura 6 muestra la distribución, y las Figuras 7–10 un chip de ejemplo por tipo con cinco paneles: VV, VH, Sentinel-2 en color natural, mapa de errores e histograma de retrodispersión.

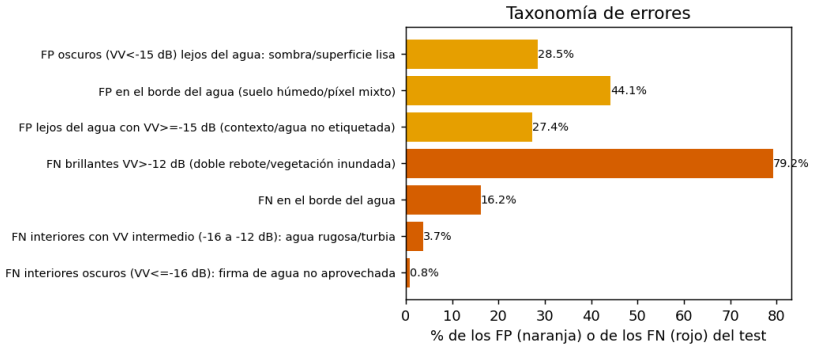


Figura 6: Distribución de los errores del test por tipo (% de los FP en naranja y de los FN en rojo).

A) Comisión: superficie oscura lejos del agua (sombra de radar / superficie lisa) (chip Pakistan_70625). En este chip el VV mediano del agua bien detectada es -15.8 dB y el de la tierra bien clasificada -8.6 dB. Hay 31,792 falsos positivos oscuros a más de 50 m del agua real, con VV mediano -17.7 dB, prácticamente igual al del agua: al sensor le llega tan poca señal como desde agua abierta. Esto pasa en laderas que quedan ocultas para el radar (sombra de radar) y en superficies lisas como pistas o suelo desnudo húmedo o recién arado, que reflejan el pulso lejos del satélite. En Sentinel-2 esos píxeles tienen MNDWI mediano -0.231 (negativo: en el óptico no parecen agua; en el agua bien detectada: 0.055) y NDVI 0.050 (suelo desnudo, zona urbana o agua). Para separarlos haría falta información adicional (modelo de elevación, Sentinel-2 o series de tiempo).

B) Omisión: agua con retrodispersión alta (doble rebote / vegetación inundada) (chip Pakistan_849790). En este chip el VV mediano del agua bien detectada es -14.5 dB y el de la tierra bien clasificada -8.0 dB. Hay 103,995 falsos negativos con VV > -12 dB (mediana -8.3 dB, $+6.2$



Figura 7: A) Comisión: superficie oscura lejos del agua (sombra de radar / superficie lisa), chip Pakistan_70625.

dB respecto al agua detectada). Si hay estructuras verticales sobre el agua, el pulso rebota en el agua, luego en una pared o un tronco, y vuelve al sensor (doble rebote): el agua se ve brillante y el modelo la confunde con tierra. En Sentinel-2 esos píxeles tienen MNDWI mediano 0.204 (positivo: en el óptico parecen agua o suelo muy húmedo; en el agua bien detectada: 0.405) y NDVI 0.074 (suelo desnudo, zona urbana o agua). Un NDVI bajo con retrodispersión alta es compatible con zonas urbanas inundadas.



Figura 8: B) Omisión: agua con retrodispersión alta (doble rebote / vegetación inundada), chip Pakistan_849790.

C) Confusión en el borde agua–suelo húmedo (chip Spain_7387658). En este chip el VV mediano del agua bien detectada es -19.9 dB y el de la tierra bien clasificada -8.6 dB. 29,147 de los 40,636 errores del chip (71.7 %) están a menos de 50 m del borde del agua real, con VV mediano -12.6 dB. En esa franja el suelo saturado tiene una retrodispersión intermedia, los píxeles de 10 m mezclan agua y tierra y hasta la etiqueta manual es dudosa; el speckle del SAR empeora la confusión. En Sentinel-2 esos píxeles tienen MNDWI mediano 0.112 (positivo: en el óptico parecen agua o suelo muy húmedo; en el agua bien detectada: 0.606) y NDVI 0.200 (vegetación moderada).



Figura 9: C) Confusión en el borde agua–suelo húmedo, chip Spain_7387658.

D) Omisión: agua con VV intermedio (rugosidad por viento / turbidez) (chip India_747992). En este chip el VV mediano del agua bien detectada es -15.0 dB y el de la tierra bien clasificada -8.8 dB. Hay 4,677 falsos negativos dentro del agua con VV intermedio (mediana -13.6 dB, entre el agua abierta y la tierra): el viento o la corriente vuelven rugosa la superficie y aumentan la retrodispersión, igual que los sedimentos en suspensión o la vegetación baja que sobresale. En Sentinel-2 esos píxeles tienen MNDWI mediano 0.722 (positivo: en el óptico parecen agua o suelo muy húmedo; en el agua bien detectada: 0.748) y NDVI -0.113 (suelo desnudo, zona urbana o agua).



Figura 10: D) Omisión: agua con VV intermedio (rugosidad por viento / turbidez), chip India_747992.

4.6 Fusión SAR + Sentinel-2 (bono)

Las imágenes S2Hand no traen máscara de nubes, así que se marcó como nube todo píxel con reflectancia azul > 0.2 y visible medio > 0.25, y se usaron los chips con menos de 5.0 % de nubes: 183 de train, 63 de validación y 66 de test. Para que la comparación sea justa, el modelo solo-SAR se volvió a entrenar con exactamente esos chips (Tabla 7).

Tabla 7: Modelos entrenados y evaluados solo con chips sin nubes (los mismos para ambos).

Modelo	Umbral	IoU	IoU medio/chip	F1	Precisión	Recall	Omisión	Comisión
Sin nubes · SAR (2 canales)	0.50	0.671	0.431	0.803	0.768	0.841	0.159	0.232
Sin nubes · SAR+S2 (15 canales)	0.55	**0.875**	**0.664**	**0.933**	0.940	0.927	0.073	0.060

Agregar las 13 bandas ópticas **mejora** el IoU en +0.204: el infrarrojo cercano y el SWIR separan el agua del suelo húmedo y de las sombras, que en el SAR se confunden. El problema en la práctica es que durante las tormentas casi no hay imágenes ópticas despejadas, que es justamente la razón para usar SAR.

5 Discusión y Conclusiones

5.1 Conclusiones

Una U-Net compacta entrenada desde cero con VV y VH segmenta el agua de inundación con IoU 0.669 en eventos vistos y 0.664 en Bolivia. Las decisiones sobre la supervisión y la pérdida se tomaron con la validación dorada, y los errores que quedan se concentran donde la física del SAR es ambigua: sombras y superficies lisas, doble rebote y bordes con suelo húmedo.

5.2 Limitaciones

- Se usó una sola semilla por configuración, así que las diferencias pequeñas entre variantes pueden deberse a la variabilidad del entrenamiento.
- Bolivia tiene 15 chips, por lo que sus intervalos de confianza son anchos.
- Se usaron los 4,160 chips débiles disponibles fuera de Bolivia, pero por tiempo de cómputo los modelos con débiles se entrenaron 10 épocas (frente a 40 de los modelos solo con dorados); con más épocas el resultado del 2a podría cambiar.
- La etiqueta dorada también es incierta en bordes y zonas urbanas, lo que limita el IoU que se puede alcanzar.
- El filtro de nubes de Sentinel-2 es una regla aproximada (S2Hand no trae máscara de nubes).
- No se usa el ángulo de incidencia ni un modelo de elevación, que ayudarían a descartar sombras de radar.

5.3 Trabajo futuro

- Agregar el ángulo de incidencia, un modelo de elevación o la coherencia interferométrica como canales de entrada, que parecen las mejoras más prometedoras para separar sombras y superficies lisas del agua.
- Repetir los experimentos con varias semillas para estimar la variación entre corridas.
- Entrenar los modelos con etiquetas débiles por más épocas para compararlos en igualdad de condiciones.

El código, las instrucciones de reproducción y la declaración de uso de IA están en el Apéndice B.

Referencias

D. Bonafilia, B. Tellman, T. Anderson, and E. Issenberg. Sen1Floods11: a georeferenced dataset to train and test deep learning flood algorithms for Sentinel-1. In *IEEE/CVF CVPR Workshops*, pages 210–211, 2020.

G. Konapala, S. V. Kumar, and S. K. Ahmad. Exploring Sentinel-1 and Sentinel-2 diversity for flood inundation mapping using deep learning. *ISPRS Journal of Photogrammetry and Remote Sensing*, 180:163–173, 2021.

I. Loshchilov and F. Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019.

S. Martinis, A. Twele, and S. Voigt. Towards operational near real-time flood detection using a split-based automatic thresholding procedure on high resolution TerraSAR-X data. *Natural Hazards and Earth System Sciences*, 9:303–314, 2009.

G. Mateo-Garcia, J. Veitch-Michaelis, L. Smith, S. V. Oprea, G. Schumann, Y. Gal, et al. Towards global flood mapping onboard low cost satellites with machine learning. *Scientific Reports*, 11:7249, 2021.

F. Milletari, N. Navab, and S.-A. Ahmadi. V-Net: Fully convolutional neural networks for volumetric medical image segmentation. In *International Conference on 3D Vision (3DV)*, pages 565–571, 2016.

O. Oktay, J. Schlemper, L. Le Folgoc, M. Lee, M. Heinrich, K. Misawa, et al. Attention U-Net: Learning where to look for the pancreas. In *Medical Imaging with Deep Learning (MIDL)*, 2018. arXiv:1804.03999.

N. Otsu. A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, 9(1):62–66, 1979.

O. Ronneberger, P. Fischer, and T. Brox. U-Net: Convolutional networks for biomedical image segmentation. In *MICCAI*, LNCS 9351, pages 234–241, 2015.

A. Twele, W. Cao, S. Plank, and S. Martinis. Sentinel-1-based flood mapping: a fully automated processing chain. *International Journal of Remote Sensing*, 37(13):2990–3004, 2016.

Z. Zhou, M. M. R. Siddiquee, N. Tajbakhsh, and J. Liang. UNet++: A nested U-Net architecture for medical image segmentation. In *DLMIA, MICCAI Workshops*, LNCS 11045, pages 3–11, 2018.

A Tablas y figuras complementarias

Este apéndice reúne las tablas de detalle y las figuras de ejemplo citadas en el texto principal.

Tabla 8: Flujo de dimensiones de la U-Net (entrada de entrenamiento de 256×256; en evaluación, 512×512).

Etapa	**Salida (canales × alto × ancho)**	**Parámetros**
Entrada (VV, VH)	$2 \times 256 \times 256$	–
Bloque inicial (DoubleConv)	$32 \times 256 \times 256$	9,920
Down 1 (MaxPool + DoubleConv)	$64 \times 128 \times 128$	55,552
Down 2	$128 \times 64 \times 64$	221,696
Down 3	$256 \times 32 \times 32$	885,760
Down 4 (cuello de botella)	$512 \times 16 \times 16$	3,540,992
Up 1 (bilineal $\times 2$ + salto + DoubleConv)	$256 \times 32 \times 32$	2,360,320
Up 2	$128 \times 64 \times 64$	590,336
Up 3	$64 \times 128 \times 128$	147,712
Up 4	$32 \times 256 \times 256$	36,992
Convolución 1×1 (logit de agua)	$1 \times 256 \times 256$	33
Total		7,849,313

Tabla 9: IoU agregado del modelo final por evento de inundación en el test.

Evento	**Chips**	**IoU**	**Órbita S1**
Pakistan	6	0.260	Descendente
USA	14	0.560	Ascendente
Somalia	6	0.582	Ascendente
Ghana	11	0.587	Ascendente
Paraguay	14	0.617	Descendente
Spain	6	0.698	Descendente
India	14	0.721	Descendente
Sri-Lanka	9	0.812	Descendente
Mekong	6	0.854	Ascendente
Nigeria	4	0.886	Ascendente

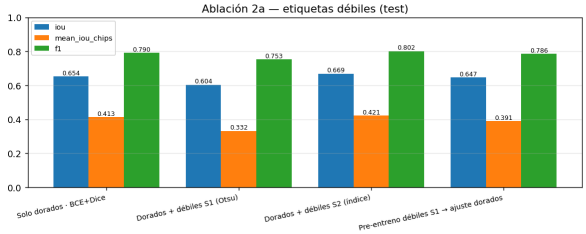


Figura 11: Ablación 2a: estrategias de supervisión en el test.

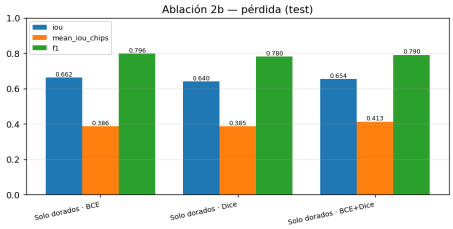


Figura 12: Ablación 2b: funciones de pérdida en el test.

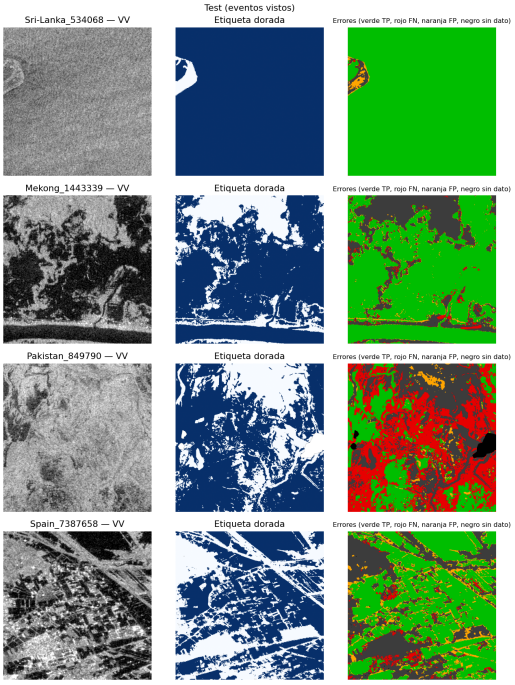


Figura 13: Ejemplos del test: VV, etiqueta dorada y mapa de errores del modelo final.

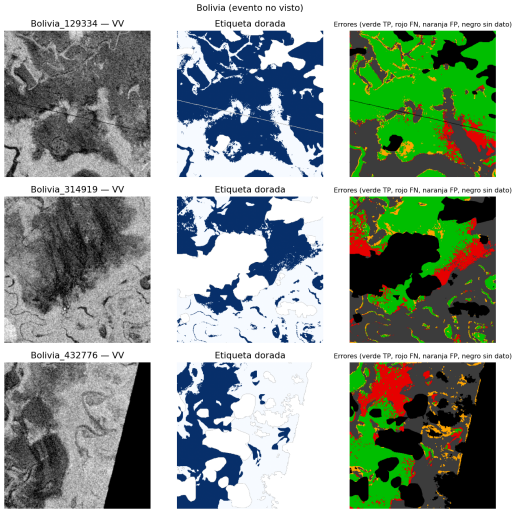


Figura 14: Ejemplos de Bolivia (evento no visto): VV, etiqueta dorada y mapa de errores.

B Material complementario y reproducibilidad

El código reproducible (descarga de datos, U-Net, funciones de pérdida, entrenamiento, evaluación y análisis de errores) se encuentra en la carpeta Pregunta02 del repositorio de GitHub: `https://github.com/dfranco79/redes_neuronales_examen_parcial_grupo05`. Para reproducir los resultados recomendamos leer primero el archivo `README.md` de esa carpeta. Todo el proyecto se ejecuta en Google Colab (con GPU) desde un solo notebook, `Pregunta2_Sen1Floods11_entrega.ipynb`, que se corre de principio a fin. Sus secciones 1 a 7 escriben el código del repositorio (`sen1floods11_unet/`); la sección 8 instala las dependencias y monta Google Drive, donde se guardan los resultados y los checkpoints para no perderlos si Colab se desconecta; la sección 9 ejecuta el pipeline completo (`main.py`), que descarga los datos de `gs://sen1floods11` (v1.1) junto con la partición oficial, revisa el inventario del dataset, entrena los ocho modelos (ablaciones 2a y 2b y bono de fusión), los evalúa en test y en Bolivia y analiza los errores del SAR; la sección 10 muestra los resultados de cada entregable, y la sección 11 empaqueta el código, los resultados, las figuras y el checkpoint del modelo final en `sen1floods11_p2_entrega.zip`.

En una GPU T4 la corrida completa de este informe tomó unos 55 minutos. Si la sesión se interrumpe, basta con volver a correr la sección 9: los modelos ya entrenados se cargan desde Drive. Con `MODO_PRUEBA = True` se hace una corrida corta que solo sirve para comprobar que el código funciona. Todos los hiperparámetros están en `src/config.py` (semilla 42).

Declaración de uso de IA. Usamos un asistente de IA para apoyar la redacción de partes del código y del informe. Las decisiones de diseño, la ejecución de los experimentos y el análisis de resultados fueron revisados por el grupo.