Monitoreo de Fauna Silvestre con Cámaras Trampa mediante YOLOv8: Generalización entre Ubicaciones y Reporte de Actividad Ecológica

Guillermo Cajo, Andre Carasas, Daniel Franco, Ivonne Lazo, David Grabiel
FIIS, Universidad Nacional de Ingeniería (UNI)
Lima, Perú
{gcajos, andre.carasas.o, daniel.franco.s, ivonne.lazo.g, david.grabiel.g}@uni.pe

Resumen

Las cámaras trampa generan más imágenes de las que un equipo humano puede revisar. Ajustamos un detector YOLOv8 sobre Caltech Camera Traps (CCT-20) para localizar y clasificar 15 categorías (14 especies y vehículos), y añadimos un módulo de monitoreo basado en reglas que resume la actividad por cámara, especie y periodo. Comparamos ubicaciones vistas (*cis*) y nuevas (*trans*), medimos el efecto del desbalance, evaluamos la robustez ante tamaño y un indicador aproximado de oclusión, y examinamos con Grad-CAM si el modelo depende del fondo. Por limitaciones de cómputo (CPU) se entrenó una sola configuración ligera (YOLOv8n, 416 px, 15 épocas, 25 % del entrenamiento). En prueba, el mAP@0.5 es 0.314 en *cis* y 0.357 en *trans* (brecha −0.043), mientras que en validación la brecha es +0.288 (0.510 frente a 0.222). Este cambio de signo y la diferencia entre dos particiones del mismo tipo (0.510 frente a 0.314) muestran que, con 5 ubicaciones por partición y una sola semilla, la variabilidad entre conjuntos es comparable a la brecha que se quiere medir. El recall con IoU $\geq$ 0.5 cae de 0.650 (objetos medianos) a 0.188 (pequeños), y el enriquecimiento de Grad-CAM es ≈1.5 en ambas particiones, sin evidencia concluyente a favor ni en contra de la memorización del fondo.

1 Motivación

Las cámaras trampa, activadas por movimiento y sin operador, son la herramienta más usada para monitorear biodiversidad en áreas protegidas, incluidas la Amazonía y los Andes peruanos. El cuello de botella es la revisión manual: gran parte de los disparos son falsas activaciones (viento, vegetación, cambios de luz) y el resto contiene animales parcialmente ocultos, pequeños o lejanos.

Además del desbalance de clases, el problema central es la generalización geográfica. Un clasificador puede aprender el fondo característico de cada cámara (una roca, un tronco, un patrón de luz) en lugar de rasgos del animal, y su desempeño cae al desplegarse en una ubicación nueva. Este trabajo cuantifica esa brecha, busca evidencia de dependencia del fondo y traduce las detecciones en un reporte útil para un equipo de manejo de fauna. Sus contribuciones son: (i) un flujo completo y documentado de datos, particiones *cis*/*trans* sin fuga de ubicaciones ni de secuencias, entrenamiento y evaluación; (ii) un análisis de robustez por tamaño y por un indicador aproximado de oclusión; (iii) un análisis con Grad-CAM; y (iv) un módulo de monitoreo ecológico demostrado sobre una cámara no vista en entrenamiento.

2 Trabajos Relacionados

Beery et al. [1] mostraron que los modelos de reconocimiento en cámaras trampa generalizan mal a ubicaciones no vistas y publicaron CCT-20 con particiones *cis* y *trans* para medir ese efecto; es el

marco experimental de este informe. Norouzzadeh et al. [2] automatizaron la identificación de especies en Snapshot Serengeti con redes profundas, y Beery et al. [3] propusieron un esquema en dos etapas con un detector genérico de animales (MegaDetector) para filtrar imágenes vacías antes de clasificar.

Para la detección se usa la familia YOLO [4], en particular la implementación de Ultralytics [5] (YOLOv8); YOLOv9 [6] es la alternativa recomendada. Para el desbalance se considera la pérdida focal [7] y el sobremuestreo de especies raras. Como aumentos que debilitan la asociación fondo–especie se emplean mixup [9] y copy-paste [10]. Para interpretar el detector se usa Grad-CAM [8], aplicado a una capa del backbone.

3 Metodología

3.1 Datos y particiones

Se usa Caltech Camera Traps de LILA BC con las cajas del subconjunto ECCV18 (63 025 imágenes con anotación y 64 926 cajas en 85 ubicaciones) y el archivo de metadatos de imágenes, del que se toman las imágenes vacías. Siguiendo la partición oficial, las 10 ubicaciones de *eccv_train* forman el conjunto de entrenamiento y las 10 de *eccv_val* son las ubicaciones nuevas. Como el archivo de particiones no trae subconjuntos *cis*/*trans* de validación y prueba, los construimos así: (a) las 10 ubicaciones nuevas se reparten por ubicación en *val_trans* (5: 7, 28, 46, 105, 125) y *test_trans* (5: 0, 40, 78, 100, 130), con semilla 42; (b) de las ubicaciones de entrenamiento se reservan secuencias completas, no fotogramas sueltos, el 10 % para *val_cis* y otro 10 % para *test_cis*, de modo que una ráfaga casi idéntica no quede repartida entre entrenamiento y evaluación. El código verifica que ninguna ubicación *trans* aparezca en entrenamiento y que ninguna secuencia esté en dos particiones. La brecha de generalización se define como la diferencia de mAP entre *cis* y *trans*.

Dos aclaraciones sobre el enunciado: el subconjunto con cajas contiene 15 categorías (14 especies y la clase *car*), no 21; y el mapeo de clases se construye dinámicamente a partir de las anotaciones.

3.2 Manejo de imágenes vacías

Las imágenes vacías se tratan como fondo puro: se exportan con archivo de etiquetas vacío y sin clase propia, para que el detector aprenda a no producir cajas. En entrenamiento se pidió una vacía por cada imagen con animal, pero en las 10 ubicaciones usadas solo hay 2 130 vacías disponibles, de las que quedaron 1 704 en entrenamiento tras reservar secuencias para *cis*. En evaluación se conservan todas las disponibles.

3.3 Detector y decisiones de entrenamiento

El notebook detecta que no hay GPU CUDA y activa una configuración ligera, que es la que produjo todos los resultados de este informe: YOLOv8n (3.0 M de parámetros, 8.1 GFLOPs) inicializado con pesos preentrenados en COCO (se reutilizaron 4 de las 15 filas de la cabeza de clasificación por coincidencia de nombre de clase), resolución de entrada 416 px, 15 épocas, tamaño de lote 8, 25 % del conjunto de entrenamiento (5 622 imágenes, de ellas 367 de fondo), optimizador AdamW elegido automáticamente (tasa inicial $5.3 \cdot 10^{-4}$), programación coseno, paciencia 15, semilla 42 y modo determinista. Se usó el esquema de aumento *strong*: mosaic 1.0, mixup 0.15, copy-paste 0.3, escala 0.6, HSV (0.03, 0.7, 0.5), rotación de 5° y volteo horizontal 0.5, pensado para romper la correlación entre fondo y especie. Como el parámetro *close_mosaic* de Ultralytics quedó en su valor por defecto (10), el mosaic solo estuvo activo en las primeras 5 de las 15 épocas. El entrenamiento tardó 3.56 h en una CPU Intel i7-1165G7. La validación durante el entrenamiento y la selección del mejor punto de control usaron *val_cis*.

El esquema *base* (volteo, escala 0.3 y HSV suave, sin mosaic, mixup ni copy-paste) y el sobremuestreo de especies raras están implementados en el notebook, pero **no se ejecutaron**; su efecto queda sin medir.

3.4 Métricas

Se reportan mAP@0.5 y mAP@0.5:0.95 con la validación de Ultralytics (conf = 0.001, IoU de NMS = 0.6) sobre cada partición, con desglose por especie. Para cuantificar el efecto del desbalance se

calcula la correlación de Spearman entre el número de imágenes de entrenamiento por especie y su AP@0.5.

3.5 Robustez ante oclusión y tamaño

El conjunto no incluye anotación de oclusión, por lo que se usa un **indicador aproximado**: para cada caja se calcula el contraste entre su interior y un anillo de fondo, y se marca si la caja toca el borde de la imagen. Se asigna nivel *alto* a las cajas que tocan el borde o con contraste en el tercil inferior, *medio* al tercil intermedio y *bajo* al superior. El tamaño se define por el área relativa de la caja (pequeño < 1 %, mediano entre 1 % y 8 %, grande > 8 %). En cada grupo se reporta el recall con IoU ≥ 0.5, coincidencia de clase y confianza mínima 0.25, sobre *test_trans*.

3.6 Grad-CAM sobre el backbone

Se calcula Grad-CAM sobre la última capa del backbone (SPPF, capa 9), con la puntuación de clase más alta de la salida como objetivo. Además de los mapas cualitativos se mide la *energía en caja* (fracción del mapa normalizado contenida en las cajas reales) y el *enriquecimiento*, que es esa fracción dividida por la fracción del área de imagen que ocupan las cajas. Un valor cercano a 1 indica atención repartida como el área, sin preferencia por el animal. Se promedian 100 imágenes con animal de *val_cis* y 100 de *val_trans*.

3.7 Módulo de monitoreo ecológico

Sistema de reglas que actúa sobre las detecciones de una cámara no vista en entrenamiento. Aplica un umbral de confianza (0.25), agrupa por especie y periodo (hora, día o mes) y calcula conteo de detecciones, fotogramas con la especie, confianza media, primera y última aparición, y la tasa de fotografías vacías frente a las que contienen fauna. Un *evento* es una secuencia de disparos en la que la especie aparece en al menos k = 2 fotogramas, lo que evita contar varias veces al mismo animal.

4 Experimentos

Se entrenó y evaluó una única configuración (YOLOv8n, aumento *strong*, sin sobremuestreo). La Tabla 1 resume el conjunto resultante. Las particiones de evaluación contienen entre el 6 % y el 11 % de imágenes vacías, muy por debajo del ≈70 % del dataset completo, porque las ubicaciones de CCT-20 tienen pocas vacías en el archivo de metadatos; en consecuencia, los falsos positivos sobre imágenes vacías pesan poco en las métricas reportadas.

Tabla 1: Resumen del conjunto usado (tabla1_dataset.csv). Para entrenar se usó el 25 % de la partición *train*.

Partición	Imágenes	Con animal	Vacías	Ubicaciones	Especies
Entrenamiento	22 487	20 783	1 704	10	15
Val. *cis*	2 775	2 555	220	10	14
Val. *trans*	10 638	9 473	1 165	5	12
Prueba *cis*	2 859	2 653	206	10	14
Prueba *trans*	10 027	9 405	622	5	14

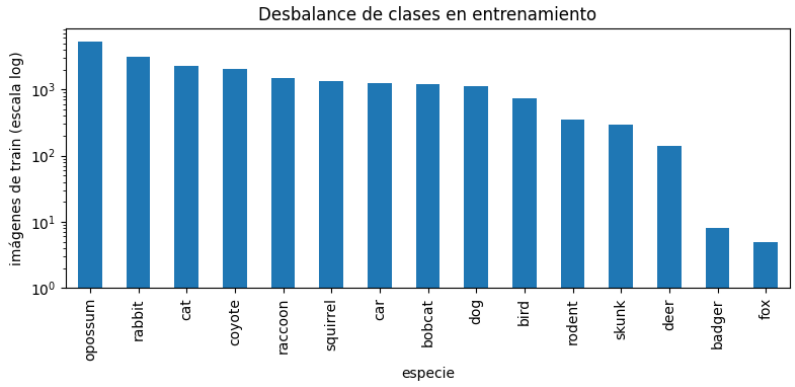


Figura 1: Imágenes de entrenamiento por especie (escala logarítmica). Cinco especies tienen menos de 400 imágenes y dos (*fox*, *badger*) menos de 10.

5 Resultados

5.1 Rendimiento por partición y brecha de generalización

Tabla 2: Métricas por partición con el punto de control seleccionado en *val_cis* (tabla2_metricas_yolov8n_strong_cpu.csv). P y R son precisión y recall medios.

Partición	mAP@0.5	mAP@0.5:0.95	P	R
Val. *cis*	0.510	0.341	0.646	0.486
Val. *trans*	0.222	0.127	0.356	0.307
Prueba *cis*	0.314	0.183	0.482	0.307
Prueba *trans*	0.357	0.237	0.536	0.356
Brecha en validación (*cis* − *trans*)	+0.288	+0.215		
Brecha en prueba (*cis* − *trans*)	−0.043	−0.055		

La validación *cis* no es independiente: se usó para elegir el punto de control, por lo que su cifra es optimista.

La brecha depende de qué par de particiones se compare. En validación, el modelo rinde mucho mejor en ubicaciones vistas (0.510 frente a 0.222), pero en prueba ocurre lo contrario (0.314 frente a 0.357). Dos hechos impiden leer cualquiera de estas cifras como una medida estable de generalización. Primero, las dos particiones *trans* difieren entre sí en 0.135 puntos de mAP@0.5 (0.222 frente a 0.357) y las dos *cis* en 0.196 (0.510 frente a 0.314), cifras del mismo orden que la brecha. Segundo, cada partición tiene un conjunto distinto de especies, y el mAP es un promedio sin ponderar sobre las especies presentes: en *test_trans*, la clase *car* aporta un AP de 0.994 y, por sí sola, eleva el mAP en ≈0.05 (sin ella sería 0.308 sobre 13 clases). Restringido a las 11 especies presentes en ambas pruebas, el AP@0.5 medio es 0.342 en *cis* y 0.356 en *trans* (cálculo propio a partir de la Tabla 3).

5.2 Desglose por especie y efecto del desbalance

Tabla 3: AP@0.5 por especie en prueba y número de imágenes de entrenamiento (tabla3_ap_por_especie_yolov8n_strong_cpu.csv). "—": la validación no reportó AP para esa clase en esa partición.

Especie	Imágenes en train	AP@0.5 *cis*	AP@0.5 *trans*
fox	4	—	0.000
badger	7	—	0.091
deer	138	0.010	—
skunk	295	0.394	0.633
rodent	354	0.000	0.000
bird	742	0.008	0.013
dog	1 130	0.357	0.598
bobcat	1 223	0.510	0.312
car	1 231	—	0.994
squirrel	1 334	0.260	0.159
raccoon	1 498	0.320	0.750
coyote	2 028	0.397	0.422
cat	2 255	0.382	0.185
rabbit	3 169	0.351	0.135
opossum	5 375	0.782	0.708

Correlación de Spearman (frecuencia en entrenamiento frente a AP@0.5): **0.517** en *cis* (n = 12 especies, p ≈ 0.085) y **0.458** en *trans* (n = 14, p ≈ 0.10; cálculo propio a partir de esta tabla).

Las especies con pocas imágenes de entrenamiento tienden a tener menor AP (*fox*, *badger*, *rodent*, *deer*), y la correlación es positiva en ambas particiones, aunque con tan pocas especies y valores de p cercanos a 0.1 no es concluyente. La frecuencia no lo explica todo: *bird* tiene 742 imágenes y un AP de 0.01, probablemente porque las aves son pequeñas (ver 5.3), y *car* alcanza 0.994 con 1 231 imágenes por ser grande y visualmente distinto. *Rabbit*, la segunda especie más frecuente, baja de

0.351 en *cis* a 0.135 en *trans*, mientras que *raccoon* sube de 0.320 a 0.750; esos cambios por especie son mayores que la brecha global y apuntan a efectos específicos de cada ubicación. En *test_cis*, *deer* tiene un AP de 0.010; con el recuento de instancias tan bajo de varias especies, estos valores son muy inestables.

5.3 Robustez ante tamaño y oclusión

Tabla 4: Recall (IoU ≥ 0.5, conf ≥ 0.25) por grupo en *test_trans* (tabla4_robustez_yolov8n_strong_cpu.csv).

Factor	Grupo	n (cajas)	Recall
Oclusión (indicador aprox.)	bajo	2 509	0.542
Oclusión (indicador aprox.)	medio	3 030	0.650
Oclusión (indicador aprox.)	alto	4 309	0.661
Tamaño relativo	grande (> 8 %)	2 107	0.701
Tamaño relativo	mediano (1–8 %)	7 032	0.650
Tamaño relativo	pequeño (< 1 %)	709	0.188

El tamaño es el factor dominante: el recall cae de 0.650 en objetos medianos a 0.188 en pequeños (−0.46) y es de 0.701 en grandes. Con el umbral de 0.25, más de cuatro de cada cinco animales pequeños no se detectan correctamente. El indicador de oclusión **no** muestra la tendencia esperada: el grupo de "alto" (0.661) rinde igual o mejor que el "bajo" (0.542). Esto indica que el indicador no mide oclusión de forma fiable: el contraste interior–anillo es bajo para animales camuflados, pero un contraste muy alto también puede darse en escenas nocturnas con flash, y el grupo "alto" incluye todas las cajas que tocan el borde, que tienden a ser animales grandes y cercanos. Por eso no se debe concluir que la oclusión no afecta al detector, sino que este indicador no permite medirla.

5.4 Grad-CAM

Tabla 5: Grad-CAM sobre la capa SPPF: fracción del mapa dentro de las cajas reales (100 imágenes por partición; tabla5_gradcam_yolov8n_strong_cpu.csv).

Partición	Energía en caja	Fracción de área	Enriquecimiento
Ubicaciones vistas (*val_cis*)	0.083	0.066	1.532
Ubicaciones nuevas (*val_trans*)	0.066	0.071	1.519

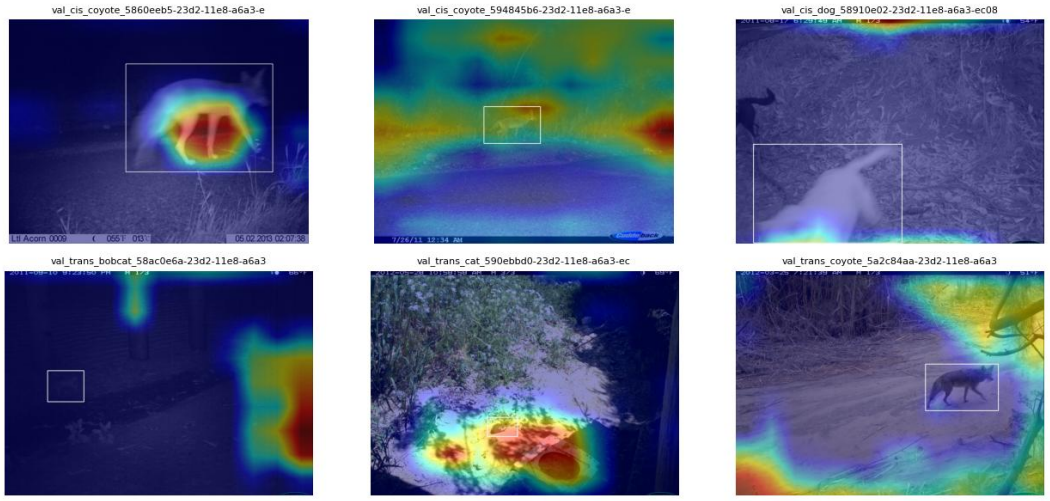


Figura 2: Grad-CAM (azul = baja, rojo = alta activación). Arriba, ubicaciones vistas (coyote, coyote, perro); abajo, ubicaciones nuevas (lince, gato, coyote). El cuadro blanco es la caja real.

El enriquecimiento es ≈1.5 en ambas particiones, es decir, la atención cae sobre el animal solo 1.5 veces más de lo que le correspondería por área, y ≈92 % del mapa queda fuera de las cajas. La diferencia entre *cis* y *trans* es mínima (1.532 frente a 1.519), por lo que esta métrica no evidencia una pérdida de atención hacia el animal en ubicaciones nuevas. Los ejemplos cualitativos son mixtos: en el coyote de arriba a la izquierda la activación se concentra en el cuerpo, mientras que en el lince de abajo a la izquierda se concentra en el borde derecho de la imagen y no en el animal, y

en el gato central cae sobre un parche de arena iluminada junto a la caja. Estos casos sugieren que, en algunas imágenes, el modelo responde a estructuras del fondo, pero seis imágenes no bastan para generalizar.

5.5 Módulo de monitoreo ecológico

Se aplicó el módulo a la cámara 100 (de *test_trans*, no vista en entrenamiento), la más poblada, con 4 320 imágenes tomadas entre mayo de 2010 y junio de 2011. Con confianza ≥ 0.25 se detectó fauna en 3 860 fotogramas y no se detectó nada en 460, lo que da una **tasa estimada de vacías de 0.106**; se observaron **11 especies distintas**. Esta tasa es una estimación basada en las predicciones del modelo, no en la verdad de campo, por lo que hereda sus errores.

Tabla 6: Actividad por especie en la cámara 100 (tabla6_monitoreo_por_especie.csv). Eventos: secuencias con la especie en ≥ 2 fotogramas.

Especie	Detecciones	Fotogramas	Eventos	Conf. media	Primera	Última
raccoon	3 078	2 582	874	0.777	2010-05-25	2011-06-05
opossum	830	817	232	0.648	2010-05-25	2011-06-05
dog	494	380	126	0.772	2010-05-25	2011-05-18
cat	206	206	47	0.580	2010-05-28	2011-06-05
coyote	124	123	31	0.543	2010-05-25	2011-05-18
squirrel	96	93	22	0.530	2010-05-30	2011-06-04
bird	77	74	17	0.415	2010-05-26	2011-04-28
rabbit	59	59	11	0.498	2010-06-05	2011-04-25
bobcat	18	18	3	0.386	2010-06-03	2011-02-25
deer	2	2	0	0.391	2010-08-13	2010-10-28
skunk	1	1	0	0.270	2010-07-17	2010-07-17

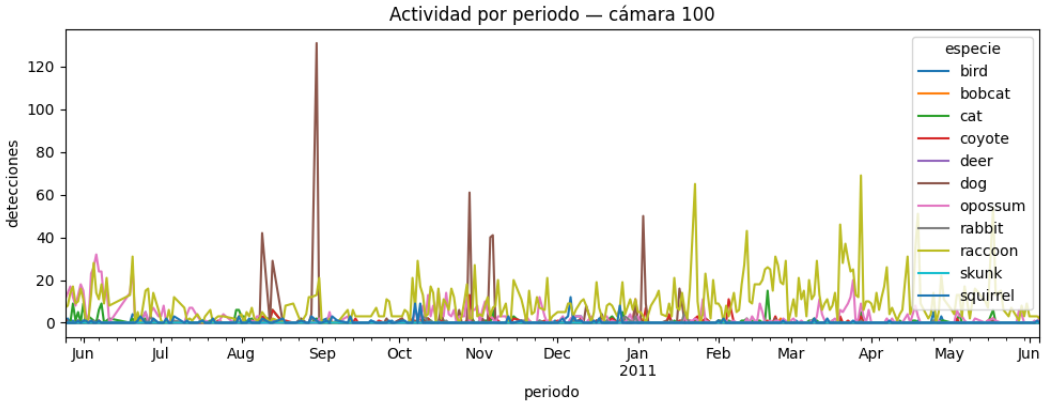


Figura 3: Detecciones diarias por especie en la cámara 100.

La cámara está dominada por el mapache (≈ 80 % de las detecciones), seguido de la zarigüeya y el perro. Las especies con menor confianza media (*deer*, *skunk*, *bobcat*, *bird*) coinciden con las de menor AP en la Tabla 3 y son las que un equipo de manejo debería revisar a mano; los dos eventos de *deer* y el de *skunk* no llegan a cumplir la regla de k = 2 fotogramas, por lo que quedan con 0 eventos. Algunos picos de la Figura 3 (por ejemplo, más de 120 detecciones de perro en un solo día a fines de agosto) merecen verificación manual, porque pueden deberse a una ráfaga real o a falsos positivos repetidos.

6 Discusión

Generalización y fondo. La evidencia es ambigua. La brecha *cis–trans* en validación (+0.288) sugiere pérdida en ubicaciones nuevas, pero la de prueba (−0.043) la contradice, y la diferencia entre particiones del mismo tipo es igual de grande. El enriquecimiento de Grad-CAM (≈1.5) es idéntico en *cis* y *trans*, lo que no apoya una dependencia del fondo *específica de ubicaciones nuevas*. Los mapas cualitativos muestran en algunos casos activación sobre estructuras del fondo, pero la métrica

global indica una atención al animal baja pero uniforme. Una sola de estas señales no basta, y Grad-CAM sobre un detector es una aproximación (aquí se usa la puntuación máxima de cualquier celda, que puede no corresponder al animal anotado, y la capa SPPF tiene una resolución espacial gruesa). Con 5 ubicaciones por partición no es posible afirmar ni descartar la memorización del fondo.

Desbalance. Las especies con muy pocos ejemplos (*fox*, *badger*) o poco visibles (*bird*, *rodent*, *deer*) tienen AP cercano a cero, y la correlación de Spearman es positiva pero débil (0.52 y 0.46). No se evaluó ninguna estrategia de mitigación, por lo que no podemos afirmar si el sobremuestreo cierra esa diferencia.

Uso responsable de IA en conservación. Un falso negativo puede excluir de las decisiones de manejo a una especie amenazada que sí estuvo presente, y su costo es acumulativo y difícil de detectar a posteriori. Un falso positivo cuesta tiempo de un especialista que revisa una detección incorrecta, un costo acotado y visible. Nuestros resultados muestran dónde se concentran los falsos negativos: con confianza 0.25, el 81 % de los animales pequeños no se detecta, y las especies raras o poco frecuentes (que suelen ser las más relevantes para conservación) son justamente las de menor AP. Por eso conviene operar con umbrales que favorezcan el recall para especies prioritarias y mantener revisión humana de las detecciones de baja confianza, como las de la Tabla 6. Además, desplegar un modelo entrenado en una región en otra (por ejemplo, uno entrenado con cámaras del suroeste de EE. UU. en la selva amazónica peruana) sin validación local es riesgoso: la fauna, la vegetación y las cámaras son distintas. Dado que incluso entre ubicaciones de un mismo dataset observamos variaciones de hasta 0.2 de mAP@0.5, es razonable esperar que la brecha entre regiones sea mayor; no lo medimos aquí. Se recomienda validar con una muestra anotada localmente y reentrenar con datos de la zona.

7 Limitaciones

- Cómputo: todo se entrenó en CPU con un modelo pequeño (YOLOv8n), 416 px, 15 épocas y el 25 % de los datos. Es probable que un YOLOv8s a 640 px con todo el entrenamiento rinda más, sobre todo en objetos pequeños.
- Solo se ejecutó una configuración y una semilla: no hay comparación entre aumentos *base* y *strong*, ni evaluación del sobremuestreo, ni estimación de la variabilidad entre corridas.
- *val_cis* se usó para elegir el punto de control, por lo que sus cifras son optimistas; el mosaic solo estuvo activo 5 de 15 épocas.
- Las particiones *trans* tienen 5 ubicaciones cada una y las especies difieren entre particiones, de modo que el mAP no es comparable directamente; las especies raras tienen muy pocas instancias y métricas inestables.
- El subconjunto tiene solo 6–11 % de imágenes vacías, por lo que la penalización de falsos positivos sobre vacías está subestimada respecto de un despliegue real.
- El indicador de oclusión es aproximado y los resultados indican que no es fiable: confunde oclusión con camuflaje, iluminación y tamaño.
- Grad-CAM se evaluó en 100 imágenes por partición y con la puntuación máxima de la salida, y las galerías cualitativas son de solo 6 imágenes.
- El módulo de eventos usa una regla simple ($\geq$ k fotogramas) y no distingue individuos; la tasa de vacías se estima con las predicciones y no se contrastó con verdad de campo.
- El mAP se calcula con la implementación de Ultralytics y puede diferir levemente del protocolo oficial del benchmark.

8 Material complementario

Código reproducible: notebook *P3_YOLO_CCT20_2.ipynb* (repositorio de GitHub: **[completar]**). Genera, en *work_q3/results*, los CSV y figuras usados en este informe (tabla1_dataset, tabla2_metricas, tabla3_ap_por_especie, tabla4_robustez, tabla5_gradcam, tabla6_monitoreo_por_especie, monitoreo_por_periodo, desbalance.png, gradcam_galeria.png y monitoreo_actividad.png). Entorno: Python 3.13, PyTorch 2.8 y Ultralytics 8.4.171. Para reproducir

las ablaciones pendientes basta cambiar *AUG* ("base" o "strong") y *OVERSAMPLE_MAX* (con *REEXPORT = True*) en la celda de configuración.

Referencias

[1] Beery, S., Van Horn, G., & Perona, P. (2018). Recognition in Terra Incognita. ECCV. arXiv:1807.04975.

[2] Norouzzadeh, M. S., et al. (2018). Automatically identifying, counting, and describing wild animals in camera-trap images with deep learning. PNAS, 115(25).

[3] Beery, S., Morris, D., & Yang, S. (2019). Efficient Pipeline for Camera Trap Image Review. arXiv:1907.06772.

[4] Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You Only Look Once: Unified, Real-Time Object Detection. CVPR.

[5] Jocher, G., Chaurasia, A., & Qiu, J. (2023). Ultralytics YOLOv8. https://github.com/ultralytics/ultralytics.

[6] Wang, C.-Y., Yeh, I.-H., & Liao, H.-Y. M. (2024). YOLOv9: Learning What You Want to Learn Using Programmable Gradient Information. arXiv:2402.13616.

[7] Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal Loss for Dense Object Detection. ICCV.

[8] Selvaraju, R. R., et al. (2017). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. ICCV.

[9] Zhang, H., Cisse, M., Dauphin, Y. N., & Lopez-Paz, D. (2018). mixup: Beyond Empirical Risk Minimization. ICLR.

[10] Ghiasi, G., et al. (2021). Simple Copy-Paste is a Strong Data Augmentation Method for Instance Segmentation. CVPR.